

INTRODUÇÃO A DATA MINING

ANÁLISE EXPLORATÓRIA DE DADOS



MANOELA KOHLER



prof.manoela@ica.ele.puc-rio.br



www.linkedin.com/in/manoelakohler

TÓPICOS

Análise exploratória

Pré-processamento

- Balanceamento
- *Outliers*
- *Missing values*
- Normalização
- Seleção de atributos (Filtros, *Wrappers*, PCA)

Associação:

- Apriori
- *FP-Growth*
- *Eclat*

Classificação:

- Regressão logística
- *Support Vector Machine (SVM)*
- Árvores de Decisão
- *Random Forest*
- *K nearest neighbors*

Regressão

- Regressão linear simples
- Regressão linear múltipla
- Regressão não linear simples
- Regressão não linear múltipla

Agrupamento

- Particionamento (K-means, K-medoids)
- Hierárquico (DIANA, AGNES)
- Densidade (DBSCAN)

Séries Temporais

- Naive
- Média Móvel
- Amortecimento exponencial
- Auto-regressivo integrados de média móvel
- Auto regressivo não linear

ESTUDOS DE CASO

- *Churn Rate*
- Consumo de cogumelos
- Classificação de plantas
- Predição de atrito e insatisfações no ambiente de trabalho
- Monitoramento de processos
- Avaliação de transações para gerenciamento de vendas e marketing
- Extração de conhecimento de consumo em shoppings
- Modelo para investidores
- Predição do uso de bicicletas para empresas de aluguel de bicicletas
- Previsão de faturamento
- Previsão do índice de preços de imóveis

FERRAMENTAS




AVALIAÇÃO

Trabalho Final

1. Será enviado pelo classroom um problema proposto por mim. Se desejarem, poderão propor seus próprios trabalhos;
2. Vocês podem escolher a ferramenta de preferência para solucionar o problema;
3. O trabalho deverá ser enviado pelo classroom em formato de relatório ou apresentação.

DEFINIÇÃO E CONCEITOS:

- Quando se procura DM no Google Images, tem-se:



DEFINIÇÃO E CONCEITOS:

- Quando se procura DM no Google Images, tem-se:



DEFINIÇÃO E CONCEITOS:

- Quando se procura DM no Google Images, tem-se:




DEFINIÇÃO E CONCEITOS: DIKW

➤ **DIKW:** *Data-Information-Knowledge-Wisdom*

- **Dados:** Resultado das experiências diárias de cada área da firma
- **Informação:** Alinhar os dados a um fim na companhia
- **Conhecimento:** Organização dos principais fatos, relações de causalidade e previsões
- **Sabedoria:** Prática apoiada sobre uma base sólida de conhecimento

DEFINIÇÃO E CONCEITOS: DIKW



DEFINIÇÃO E CONCEITOS:

- Bem, mas o que é DM?



DEFINIÇÃO E CONCEITOS:

➤ Definição :

- A mineração de dados pode ser considerada como uma parte do processo de Descoberta de Conhecimento em Banco de Dados (KDD – Knowledge Discovery in Databases).
- Segundo Goebel (1999), o termo KDD é usado para representar o processo de tornar dados de baixo nível em conhecimento de alto nível, enquanto mineração de dados pode ser definida como a extração de padrões ou modelos de dados observados.

DEFINIÇÃO E CONCEITOS:

➤ **DM é ir além:**


- **Associar** para formar nichos
- **Descrever** para caracterizar padrões
- **Prever** para identificar tendências e limites

Acima de tudo, **Agregar Valor ao Empreendimento!**

DEFINIÇÃO E CONCEITOS:

➤ **Data Mining, acima de tudo, é:**

- Uma área interdisciplinar: a mineração de dados combina métodos e ferramentas das seguintes áreas: aprendizagem de máquina, estatística, banco de dados, sistemas especialistas e visualização de dados;
- Parte importante de um Projeto de Business Intelligence bem sucedido;
- Um procedimento para Extração de Informação e Conhecimento em bases de dados.



5 Problemas Típicos de DATA MINING


5 PROBLEMAS TÍPICOS DE DM

- Previsão de Faturamento em Varejo
- Avaliação de Crédito
- Determinação de Localidades Promissoras para Abertura de Novas Filiais
- Definição de grupos de consumo para segmentação de mercado
- Oferta de Novos Serviços e Produtos (Netflix, Amazon, Americanas.com etc.)

PREVISÃO DE FATURAMENTO EM VAREJO

➤ Perguntas do Gestor:

- Qual o faturamento esperado para o próximo trimestre?
- Qual o pior cenário para o faturamento?




AVALIAÇÃO DE CRÉDITO



- Perguntas do Gestor:
- Será que ele vai pagar o empréstimo?
 - Qual o melhor modelo de financiamento para esse cliente (juros, prazo, etc.)?

LOCALIDADES PROMISSORAS PARA ABERTURA DE NOVAS FILIAIS

➤ Perguntas do Gestor:



- Qual o local mais promissor para abrir uma nova filial?
- Em quanto tempo terei de volta o investimento realizado?

DEFINIÇÃO DE GRUPOS DE CONSUMO PARA SEGMENTAÇÃO DE MERCADO



OFERTA DE NOVOS SERVIÇOS E PRODUTOS

➤ Perguntas do Gestor:

Quem observa esse produto, tem interesse em ver qual outro?

Quem observa esse produto, costuma comprar qual outro?



OFERTA DE NOVOS SERVIÇOS E PRODUTOS

Quem viu este produto acabou comprando

46% compraram



Tablet LG G Pad V700 16GB Wi-Fi
Tela 10" Android...

★★★★★ (11)

De R\$ 1.099,00

R\$ 799,00

ou 10x de R\$ 79,90 sem juros

ou em 12x de R\$ 66,58
sem juros no Cartão Submarino

Frete grátis

10%OFF no boleto

+ LG

Veja em outras lojas

14% compraram



Tablet LG G Pad V700 16GB Wi-Fi
Tela 10" Android...

★★★★★ (11)

De R\$ 999,00

R\$ 799,00

ou 10x de R\$ 79,90 sem juros

ou em 12x de R\$ 66,58
sem juros no Cartão Submarino

Frete grátis

10%OFF no boleto

+ LG

Veja em outras lojas

9% compraram



Tablet LG G Pad V700 16GB Wi-Fi
Tela 10" Android...

★★★★★ (28)

De R\$ 1.099,00

R\$ 799,00

ou 10x de R\$ 79,90 sem juros

ou em 12x de R\$ 66,58
sem juros no Cartão Submarino

Frete grátis

10%OFF no boleto

+ LG

Veja em outras lojas

5% compraram



Tablet Samsung Galaxy Tab 4
T530N 16GB Wi-Fi Tela...

★★★★★ (23)

De R\$ 1.299,00

R\$ 1.149,00

ou 10x de R\$ 114,90 sem juros

ou em 12x de R\$ 95,75
sem juros no Cartão Submarino

Frete grátis

10%OFF no boleto

+ Samsung

Veja em outras lojas

Quem viu este produto viu também



Tablet Lenovo Yoga 16GB Wi-Fi
Tela IPS 10,1"...

★★★★★ (12)

De R\$ 899,00

R\$ 809,10

ou 10x de R\$ 80,91 sem juros

ou em 12x de R\$ 67,42
sem juros no Cartão Submarino

Frete grátis

10%OFF no boleto

+ Lenovo

Veja em outras lojas



Tablet Intel TM105A 16GB Wi-Fi
Tela TFT 10,1"...

De R\$ 799,00

R\$ 719,10

ou 10x de R\$ 71,91 sem juros

ou em 12x de R\$ 59,93
sem juros no Cartão Submarino

Frete grátis

10%OFF no boleto

+ Intel

Veja em outras lojas



Tablet LG G Pad V480 16GB Wi-Fi
Tela 8" Android...

★★★★★ (7)

De R\$ 899,00

R\$ 799,00

ou 10x de R\$ 79,90 sem juros

ou em 12x de R\$ 66,58
sem juros no Cartão Submarino

Frete grátis

10%OFF no boleto

+ LG

Veja em outras lojas



Tablet LG G Pad V400 8GB Wi-Fi
Tela IPS WXGA 7"...

★★★★★ (12)

De R\$ 699,00

R\$ 479,00

ou 10x de R\$ 47,90 sem juros

ou em 12x de R\$ 39,92
sem juros no Cartão Submarino

Frete grátis

10%OFF no boleto

+ LG

Veja em outras lojas

5 CLASSES DE PROBLEMAS DE DM



5 CLASSES DE PROBLEMAS DE DM

- **Previsão:**
 - Previsão de Vendas em Varejo
- **Classificação:**
 - Avaliação de Crédito
- **Regressão:**
 - Determinação de Localidades Promissoras para Abertura de Novas Filiais
- **Agrupamento:**
 - Definição de grupos de consumo para segmentação de mercado
- **Associação:**
 - Oferta de Novos Serviços e Produtos (Netflix, Amazon, Americanas.com, etc.)


Machine Learning

Supervisionado


Não Supervisionado

Reforço


Classificação
Regressão
Previsão de séries temporais



Agrupamento
Associação



Aprendizado através da interação de agentes com um ambiente




SUPERVISIONADO

- Aproximador: função mapeia entradas e saída.


Classificação

Rótulo é categórico.



Regressão

Rótulo é contínuo.



Previsão de Séries


Rótulo é contínuo e dependente do tempo.



NÃO SUPERVISIONADO


Agrupamento

Descoberta de semelhanças e grupos entre registros.




Associação

Descoberta de relações entre variáveis.



ETAPAS DE UM PROJETO DE DATA MINING

ESQUEMA BÁSICO DE UM PROJETO DE DM



MORAL DA HISTÓRIA



“Data is Knowledge, and Knowledge is Power.”

Análise Exploratória de Dados

ANÁLISE EXPLORATÓRIA DE DADOS

O primeiro passo em qualquer análise de dados consiste em explorar os dados coletados.

A análise exploratória nos fornece uma ideia de como os nossos dados se distribuem e qual a forma que apresentam.

Além disso, na análise exploratória podemos verificar se os pressupostos teóricos exigidos para a análise que escolhemos são ou não verificados.

ANÁLISE EXPLORATÓRIA DE DADOS

- **Organização e Classificação dos Dados**
- **Cálculo de Medidas Resumo para os Dados**
- **Visualização do Conjunto de Dados**

Organização e Classificação dos Dados

ORGANIZAÇÃO E CLASSIFICAÇÃO

Há 3 Tipos de Variáveis:

- Variável Categórica: Valores em um Conjunto Finito e Não Possui Ordenação
 - Exemplo: Sexo, Tipo de Moradia, Estado Civil, etc.
- Variável Discreta: Valores em um Conjunto Finito e Possui Ordenação
 - Exemplo: Idade, Número de Amigos, Fotos, etc.
- Variável Contínua: Valores em um Conjunto Infinito e Possui Ordenação
 - Exemplo: Peso, Altura, Tempo Online, etc.

ORGANIZAÇÃO E CLASSIFICAÇÃO

- É bastante comum organizar os dados em **Tabelas Extensivas**:

id	Idade	Renda	...	Sexo
1	25	1400	...	M
2	35	2400	...	F
...	...	...	...	...
n	45	3400	...	F

- Ideal para qualquer tipo de variável: Idade, Sexo, Peso, Grau de Satisfação, Amizade, etc.

ORGANIZAÇÃO E CLASSIFICAÇÃO

- Outra forma importante é a **Tabela de Contingência**:

		Sexo	
		M	F
Daltonismo	#	50	30
		25	20

- Cruzamento de Informação entre Variáveis Categóricas

ORGANIZAÇÃO E CLASSIFICAÇÃO

- Outra forma importante é a **Tabela de Classes de Frequência**:

Renda	# Indivíduos
$0 \mapsto 1000$	30
$1000 \mapsto 2000$	22
...	...
$5000 \mapsto \text{inf}$	5
Total	80

- Arranjo de informação comumente usado para Variáveis Contínuas e Discretas

ORGANIZAÇÃO E CLASSIFICAÇÃO - EXEMPLO



Organização e Classificação

- ID
- Nome
- Idade (Variável Discreta)
- Sexo (Variável Categórica)
- Número de Amigos (Variável Discreta)
- Tempo Online no Facebook (Variável Contínua)

Medidas de Resumo


MEDIDAS RESUMO

Valores numéricos obtidos a partir de uma amostra que:

- Resumem a informação contida nos dados;
- Exibem o comportamento da distribuição da amostra.
 - Valores centrais, valores extremos, dispersão, assimetria, média, mediana, moda, etc.




MEDIDAS DE LOCAÇÃO

- Estatística que visam a apresentar a região em que os dados estão mais concentrados






MEDIDAS DE DISTRIBUIÇÃO DE FREQUÊNCIAS

- Estatística que visam a revelar o nível de espalhamento da amostra




MEDIDAS DE ASSOCIAÇÃO


- Estatística que visam a aferir o Sentido e Intensidade da Relação entre Variáveis




Visualização



VISUALIZAÇÃO




Usuários por faixa etária versus conteúdo



VISUALIZAÇÃO

Índice de Aceitação dos Candidatos à Prefeitura da Cidade K (2012)



The Home of Data Science & Machine Learning

Kaggle helps you learn, work, and play

Create an account

or

Host a competition



Competitions ›

Climb the world's most elite machine learning leaderboards

[Want to host a competition?](#)

Datasets ›

Explore and analyze a collection of high quality public datasets

Kernels ›

Run code in the cloud and receive community feedback on your work

RECOMENDAÇÕES

Medium

<https://medium.com/>

How is AI transforming technology and technical communication?

In early December, researchers at DeepMind, the artificial-intelligence company owned by Google's parent corporation, Alphabet Inc., filed...

Rolfe DH

Dec 31, 2018 • 3 min read



Tech Giants, Gorging on AI Professors Is Bad for You

If industry keeps hiring the cutting-edge scholars, who will train the next generation of innovators in artificial intelligence?

Bloomberg View in Bloomberg View

Jan 7 • 4 min read ★



Interaction design for virtual assistants

This is the year smart speakers boomed.

Corbet Fawcett in UX Collective

Jan 7 • 10 min read



<https://www.kdnuggets.com>

Most Popular Dec 17-23

1. **NEW** Why You Shouldn't be a Data Science Generalist, by Jeremie Harris
2. **NEW** Introduction to Statistics for Data Science, by Diogo Menezes Borges
3. **NEW** Top Python Libraries in 2018 in Data Science, Deep Learning, Machine Learning
4. **NEW** 9 Must-have skills you need to become a Data Scientist, updated
5. **NEW** 10 More Must-See Free Courses for Machine Learning and Data Science
6. **NEW** Feature engineering, Explained
7. **NEW** Machine Learning & AI Main Developments in 2018 and Key Trends for 2019



RECOMENDAÇÕES

<https://arXiv.org>



Rectangular Snip

arXiv is a free distribution service and an open-access archive for 2,035,774 scholarly articles in the fields of physics, mathematics, computer science, quantitative biology, quantitative finance, statistics, electrical engineering and systems science, and economics. Materials on this site are not peer-reviewed by arXiv.



<https://paperswithcode.com/>

Browse State-of-the-Art

6,517 benchmarks 2,768 tasks 66,454 papers with code

Computer Vision



130 benchmarks
2535 papers with code



311 benchmarks
2187 papers with code



216 benchmarks
1908 papers with code



176 benchmarks
836 papers with code



103 benchmarks
802 papers with code

[See all 1235 tasks](#)

Natural Language Processing



315 benchmarks
1625 papers with code




73 benchmarks
1440 papers with code



117 benchmarks
1419 papers with code



72 benchmarks
885 papers with code



87 benchmarks
698 papers with code

[See all 533 tasks](#)

BASE MUSHROOM

Mushroom: <https://www.kaggle.com/uciml/mushroom-classification>

Este conjunto de dados está desfrutando de novos picos de popularidade. Aprenda quais características soletram a morte certa e quais são mais palatáveis neste conjunto de dados de características de cogumelo.

Este conjunto de dados inclui descrições de amostras hipotéticas correspondentes a 23 espécies de cogumelos. Cada espécie é identificada como definitivamente comestível, definitivamente venenosa, ou de consumo desconhecido e não recomendado. Esta última classe foi combinada com a venenosa.

O guia (de onde foram retiradas as características dos cogumelos) afirma claramente que **não existe uma regra simples para determinar a comestibilidade de um cogumelo.**



BASE MUSHROOM

Mushroom characteristics

5 Sections:

1. Cap
2. Ring
3. Veil
4. Gills
5. Stalk

