

TRATAMENTO DE DADOS



PÓS-GRADUAÇÃO EM CIÊNCIA DE DADOS

MANOELA KOHLER



prof.manoela@ica.ele.puc-rio.br



www.linkedin.com/in/manoelakohler

TÓPICOS

Análise exploratória

Pré-processamento

- Balanceamento
- *Outliers*
- *Missing values*
- Normalização
- Seleção de atributos (Filtros, *Wrappers*, PCA)

Associação:

- Apriori
- *FP-Growth*
- *Eclat*

Classificação:

- Regressão logística
- *Support Vector Machine (SVM)*
- Árvores de Decisão
- *Random Forest*
- *K nearest neighbors*

Regressão

- Regressão linear simples
- Regressão linear múltipla
- Regressão não linear simples
- Regressão não linear múltipla

Agrupamento

- Particionamento (K-means, K-medoids)
- Hierárquico (DIANA, AGNES)
- Densidade (DBSCAN)

Séries Temporais

- Naive
- Média Móvel
- Amortecimento exponencial
- Auto-regressivo integrados de média móvel
- Auto regressivo não linear


Recapitulação

DEFINIÇÃO E CONCEITOS:

- Quando se procura DM no Google Images, tem-se:



DEFINIÇÃO E CONCEITOS: INTERDISCIPLINAR




5 CLASSES DE PROBLEMAS DE DM



ETAPAS DE UM PROJETO DE DATA MINING

ESQUEMA BÁSICO DE UM PROJETO DE DM



Análise Exploratória de Dados

BASE MUSHROOM

Mushroom: <https://www.kaggle.com/uciml/mushroom-classification>

Este conjunto de dados está desfrutando de novos picos de popularidade. Aprenda quais características soletram a morte certa e quais são mais palatáveis neste conjunto de dados de características de cogumelo.

Este conjunto de dados inclui descrições de amostras hipotéticas correspondentes a 23 espécies de cogumelos. Cada espécie é identificada como definitivamente comestível, definitivamente venenosa, ou de consumo desconhecido e não recomendado. Esta última classe foi combinada com a venenosa.

O guia (de onde foram retiradas as características dos cogumelos) afirma claramente que **não existe uma regra simples para determinar a comestibilidade de um cogumelo.**




BASE MUSHROOM

Mushroom characteristics

5 Sections:

1. Cap
2. Ring
3. Veil
4. Gills
5. Stalk



Tratamento de Dados

Missing Values

MISSING VALUES

- Muito comum no mundo real;
- Atributos novos que surgem com o passar do tempo e com a necessidade de novas informações por parte das empresas;
- Atributos não preenchidos por falta de obrigatoriedade;

OBS: Verificar se o número de registros com dados faltantes (para um atributo específico) por si só não justifica a remoção do atributo;

SUBSTITUIÇÃO PELA MÉDIA

Idade	Estado Civil	Nota	Atrito
35	Casado	9	Sim
53	?	7	Sim
68	Casado	10	Não
20	Solteiro	8	Não
29	Casado	?	Sim

$$\text{Média: } 9 + 7 + 10 + 8 / 4 = 8.5$$

SUBSTITUIÇÃO PELA MÉDIA

Idade	Estado Civil	Nota	Atrito
35	Casado	9	Sim
53	?	7	Sim
68	Casado	10	Não
20	Solteiro	8	Não
29	Casado	8.5	Sim

SUBSTITUIÇÃO PELA MÉDIA BASEADO EM OUTRO ATRIBUTO

Idade	Estado Civil	Nota	Atrito
35	Casado	9	Sim
53	?	7	Sim
68	Casado	10	Não
20	Solteiro	8	Não
29	Casado	?	Sim

$$\text{Média: } 9 + 7 / 2 = 8$$

SUBSTITUIÇÃO PELA MÉDIA BASEADO EM OUTRO ATRIBUTO

Idade	Estado Civil	Nota	Atrito
35	Casado	9	Sim
53	?	7	Sim
68	Casado	10	Não
20	Solteiro	8	Não
29	Casado	8	Sim


SUBSTITUIÇÃO PELO VALOR MAIS FREQUENTE

Idade	Estado Civil	Nota	Atrito
35	Casado	9	Sim
53	?	7	Sim
68	Casado	10	Não
20	Solteiro	8	Não
29	Casado	8	Sim

SUBSTITUIÇÃO PELO VALOR MAIS FREQUENTE

Idade	Estado Civil	Nota	Atrito
35	Casado	9	Sim
53	Casado	7	Sim
68	Casado	10	Não
20	Solteiro	8	Não
29	Casado	8	Sim

MISSING



Normalização

NORMALIZAÇÃO

- Dar aos atributos pesos iguais;
- Diminuir o tempo de convergência dos algoritmos;

Conversão de atributos

Redução de Dimensionalidade


REDUÇÃO DE DIMENSIONALIDADE

Maldição da dimensionalidade (Curse of dimensionality)

- Termo que se refere a vários fenômenos que surgem na análise de dados em espaços com muitas dimensões (atributos);
- Muitas vezes com centenas ou milhares de dimensões;
- Basicamente, adicionar características não significa sempre melhora no desempenho de um classificador.

REDUÇÃO DE DIMENSIONALIDADE

- De modo geral, o desempenho de um classificador tende a se degradar a partir de um determinado n° de atributos
 - Mesmo que eles sejam atributos úteis



REDUÇÃO DE DIMENSIONALIDADE

Tarefas:

- Redução do número de atributos.

Objetivos

- Diminuir o custo do aprendizado;
- Aumentar a precisão do algoritmo;
- Gerar modelos compactos mais fáceis de interpretar.

REDUÇÃO DE DIMENSIONALIDADE

Em geral, espera-se que todos os atributos sejam relevantes porém nem sempre é possível garantir isso.

Além disso, alguns atributos são redundantes e assim poderiam ser eliminados.

Objetivo:

- Definir conjunto de atributos que sejam relevantes e não-redundantes

REDUÇÃO DE DIMENSIONALIDADE

➤ Abordagens

- Seleção X Agregação de Atributos

➤ Seleção de atributos:

- Escolha de um sub-conjunto de atributos relevantes dentre os atributos disponíveis
 - E.g., Filtros e Wrappers

➤ Agregação de atributos:

- Criação de novos atributos a partir da combinação dos atributos existentes
 - E.g., PCA


Seleção de Atributos

SELEÇÃO DE ATRIBUTOS

Filtros

Os métodos de seleção de filtro aplicam uma medida estatística para atribuir uma pontuação a cada atributo.

Os atributos são ranqueados pela pontuação e então podem ser selecionados para serem mantidos ou removidos do conjunto de dados.



GANHO DE INFORMAÇÃO

Predictors				Target
Outlook	Temp.	Humidity	Windy	Play Golf
Rainy	Hot	High	False	No
Rainy	Hot	High	True	No
Overcast	Hot	High	False	Yes
Sunny	Mild	High	False	Yes
Sunny	Cool	Normal	False	Yes
Sunny	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Rainy	Mild	High	False	No
Rainy	Cool	Normal	False	Yes
Sunny	Mild	Normal	False	Yes
Rainy	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Sunny	Mild	High	True	No

1. Calcula-se a entropia para classe (0 = dados homogêneos; 1 = dados igualmente distribuídos).

Play Golf	
Yes	No
9	5

$$\begin{aligned}
 \text{Entropy(PlayGolf)} &= \text{Entropy}(5,9) \\
 &= \text{Entropy}(0.36, 0.64) \\
 &= -(0.36 \log_2 0.36) - (0.64 \log_2 0.64) \\
 &= 0.94
 \end{aligned}$$

$$E(S) = \sum_{i=1}^c -p_i \log_2 p_i$$

GANHO DE INFORMAÇÃO

2. Divide-se a base nos diferentes atributos e calcula-se a entropia para cada um deles. Calcula-se o ganho de informação (entropia para classe – entropia para atributo).

		Play Golf		
		Yes	No	
Outlook	Sunny	3	2	5
	Overcast	4	0	4
	Rainy	2	3	5
				14

$$\begin{aligned} E(\text{PlayGolf}, \text{Outlook}) &= P(\text{Sunny}) * E(3,2) + P(\text{Overcast}) * E(4,0) + P(\text{Rainy}) * E(2,3) \\ &= (5/14) * 0.971 + (4/14) * 0.0 + (5/14) * 0.971 \\ &= 0.693 \end{aligned}$$

$$\begin{aligned} G(\text{PlayGolf}, \text{Outlook}) &= E(\text{PlayGolf}) - E(\text{PlayGolf}, \text{Outlook}) \\ &= 0.940 - 0.693 = 0.247 \end{aligned}$$

O ganho de informação é baseado na diminuição da entropia depois que uma base de dados é subdividida em um atributo.

GANHO DE INFORMAÇÃO

2. Divide-se a base nos diferentes atributos e calcula-se a entropia para cada um deles. Calcula-se o ganho de informação (entropia para classe – entropia para atributo).

		Play Golf	
		Yes	No
Outlook	Sunny	3	2
	Overcast	4	0
	Rainy	2	3
Gain = 0.247			

		Play Golf	
		Yes	No
Temp.	Hot	2	2
	Mild	4	2
	Cool	3	1
Gain = 0.029			

		Play Golf	
		Yes	No
Humidity	High	3	4
	Normal	6	1
Gain = 0.152			

		Play Golf	
		Yes	No
Windy	False	6	2
	True	3	3
Gain = 0.048			

O ganho de informação é baseado na diminuição da entropia depois que uma base de dados é subdividida em um atributo.


$$Gain(T, X) = Entropy(T) - Entropy(T, X)$$

SELEÇÃO DE ATRIBUTOS

Wrapper

Os métodos Wrapper consideram a seleção de um conjunto de recursos como um **problema de busca**, onde diferentes combinações são preparadas, avaliadas e comparadas com outras combinações. Um modelo preditivo é usado para avaliar uma combinação de características e atribuir uma pontuação baseada na precisão do modelo.

Suponha uma base com 5 atributos:



Cromossomo: cada gene pode assumir um de dois valores: 0 ou 1.


0 = Sem o respectivo atributo;
1 = Com o respectivo atributo;

SELEÇÃO DE ATRIBUTOS

Wrapper

Os métodos Wrapper consideram a seleção de um conjunto de recursos como um **problema de busca**, onde diferentes combinações são preparadas, avaliadas e comparadas com outras combinações. Um modelo preditivo é usado para avaliar uma combinação de características e atribuir uma pontuação baseada na precisão do modelo.

Suponha uma base com 5 atributos:



Cada indivíduo criado durante a evolução do AG é apresentado ao algoritmo classificador.

SELEÇÃO DE ATRIBUTOS

Wrapper

Os métodos Wrapper consideram a seleção de um conjunto de recursos como um **problema de busca**, onde diferentes combinações são preparadas, avaliadas e comparadas com outras combinações. Um modelo preditivo é usado para avaliar uma combinação de características e atribuir uma pontuação baseada na precisão do modelo.

Suponha uma base com 5 atributos:

A_1	A_2	A_3	A_4	A_5
0	1	1	0	1

Toda a base com os três atributos escolhidos (A_2 , A_3 e A_5) é usada para treinar o algoritmo classificador e a função de avaliação pode ser, por exemplo, a acurácia de treinamento.




Acurácia =
30%

SELEÇÃO DE ATRIBUTOS

Wrapper

Os métodos Wrapper consideram a seleção de um conjunto de recursos como um **problema de busca**, onde diferentes combinações são preparadas, avaliadas e comparadas com outras combinações. Um modelo preditivo é usado para avaliar uma combinação de características e atribuir uma pontuação baseada na precisão do modelo.

Suponha uma base com 5 atributos:



O algoritmo genético evolui até chegar à resposta ótima.

Acurácia =
93%



1 1 0 0 1

SELEÇÃO DE ATRIBUTOS

- Embarcados (Embedded)
 - Processo de seleção faz parte do algoritmo de aprendizado
 - Exemplo: Árvore de Decisão

Agregação de Atributos

AGREGAÇÃO DE ATRIBUTOS

- Exemplo: dois atributos → “massa” e “volume”
- Esses atributos podem ser agregados em um único atributo: “densidade”
- $\text{densidade} = \text{massa} / \text{volume}$
- Nesse caso, não há perda de informação.

AGREGAÇÃO DE ATRIBUTOS

PCA

Consiste em transformar um conjunto de variáveis originais em outro conjunto de variáveis de mesma dimensão denominadas de componentes principais.

Os componentes principais apresentam propriedades importantes:

- Cada componente principal é uma combinação linear de todas as variáveis originais;
- Todos os componentes são ortogonais entre si, portanto não há informações redundantes;
- São estimados com o propósito de reter, em ordem de estimação, o máximo de informação, em termos da variação total contida nos dados.

Redução de massa de dados, com menor perda possível da informação.

Análise de componentes principais é completamente reversível, tornando-a uma ferramenta versátil e útil para redução de dados, compressão de dados, entre outros.

Component	Proportion of Variance	Cumulative Variance
PC 1	0.121	0.121
PC 2	0.078	0.199
PC 3	0.069	0.268
PC 4	0.062	0.330
PC 5	0.054	0.384
PC 6	0.048	0.431
PC 7	0.042	0.474
PC 8	0.039	0.512
PC 9	0.035	0.547
PC 10	0.034	0.581
PC 11	0.028	0.609
PC 12	0.026	0.635
PC 13	0.025	0.660
PC 14	0.024	0.685
PC 15	0.024	0.708
PC 16	0.023	0.731
PC 17	0.020	0.751
PC 18	0.019	0.770
PC 19	0.018	0.788
PC 20	0.018	0.805
PC 21	0.017	0.822
PC 22	0.016	0.839


Component	Proportion of Variance	Cumulative Variance
PC 24	0.015	0.869
PC 25	0.014	0.883
PC 26	0.013	0.897
PC 27	0.012	0.908
PC 28	0.011	0.920
PC 29	0.011	0.931
PC 30	0.010	0.941
PC 31	0.010	0.951
PC 32	0.010	0.961
PC 33	0.008	0.969
PC 34	0.007	0.976
PC 35	0.006	0.982
PC 36		
PC 37		
PC 38		
PC 39		
PC 40		
PC 41		

Limiar de variância = 0.95

Resulta em 31 componentes principais
de um total de 49 atributos

Balanceamento de Dados

BALANCEAMENTO DE DADOS







BALANCEAMENTO DE DADOS

A grande maioria das bases de dados não têm o mesmo número de instâncias em cada classe, mas quando essa diferença é pequena não há problemas.

Em algumas bases, esse comportamento é esperado. Por exemplo, em bases de dados que representam transações fraudulentas. A maioria das transações serão “Normais”, e uma pequena minoria de transações serão “Fraudulentas”.


BALANCEAMENTO DE DADOS



Classe 1: 95% dos dados
Classe 2: 5% dos dados

Classificadores ficam “preguiçosos”, já que consegue-se uma alta acurácia classificando todos os dados como “Classe 1”. No exemplo, acurácia de 95%.

BALANCEAMENTO DE DADOS



BALANCEAMENTO DE DADOS

1. Coletar mais dados
2. Utilizar diferentes métrica de performance

- Matriz de confusão
- Precisão
- Recall
- Kappa
- F1 score

*Matriz de
Confusão*

	Classificação Positiva	Classificação Negativa
Classe Positiva	Verdadeiro Positivo (TP)	Falso Negativo (FN)
Classe Negativa	Falso Positivo (FP)	Verdadeiro Negativo (TN)

Recall (sensibilidade)

$$\text{Razão de Verdadeiros Positivos} = \frac{TP}{TP + FN}$$

Denota o percentual de objetos positivos que foram recuperados pelo classificador.

Precisão


$$Pr ec = \frac{TP}{TP + FP}$$

Medida de exatidão: percentual de acerto em relação a todos os objetos tidos como positivos

BALANCEAMENTO DE DADOS

3. Reamostrar conjunto de dados


- Over-sampling (aleatório)



BALANCEAMENTO DE DADOS

3. Reamostrar conjunto de dados

- Over-sampling (aleatório)
- Under-sampling (aleatório)




BALANCEAMENTO DE DADOS

4. Gerar amostras aleatórias

Exemplo: SMOTE (Synthetic Minority Over-Sampling Technique)

Método de over-sampling que gera amostras sintéticas da classe rara (ao invés de criar cópias) perturbando um atributo por vez por um valor dentro da diferença entre os exemplos vizinhos.




BALANCEAMENTO DE DADOS

❑ *Tomek Links* (Tomek, 1976)

- ❑ Remove ruídos e pontos de fronteira;
- ❑ Pode ser usado como
 - ❑ under-sampling (remove o ponto da classe predominante (-))
 - ❑ data cleaning (remove os dois pontos)

Dados:


$$\begin{cases} E_i - \text{classe A} \\ E_j - \text{classe B} \end{cases}$$


BALANCEAMENTO DE DADOS

- ❑ *Edited Nearest Neighbor (ENN)* (Wilson, 1972)

- ❑ **Cleaning:**


- ❑ dado um exemplo, procura os três vizinhos mais próximos
 - ❑ Se o exemplo difere da classe de 2 dos 3 exemplos, o mesmo é removido.



BALANCEAMENTO DE DADOS

5. Testar em diferentes algoritmos


Não se deve ter um algoritmo favorito nesse caso. Tente diferentes algoritmos.



BALANCEAMENTO DE DADOS

6. Penalização

Custo adicional para classificação errada da classe rara.




Razão entre classes: 5:1

BALANCEAMENTO DE DADOS


6. Penalização

Custo adicional para classificação errada da classe rara.




Razão entre classes: 5:1

GANS



Application

Theory



Outliers

OUTLIERS

Algoritmos de aprendizado de máquina são sensíveis à distribuição e intervalo dos dados. *Outliers* podem enviesar e induzir ao erro, resultando em um tempo de treinamento maior, menor acurácia e modelos piores.



1. Análise de valores extremos;
2. Métodos de proximidade
 - (e.g. k-means);
3. Métodos de projeção
 - (e.g. kohonen).

ESTUDO DE CASO

<http://archive.ics.uci.edu/ml/datasets/SECOM>

Um complexo processo de fabricação de semi-condutores moderno é normalmente feito sob vigilância consistente através do monitoramento de sinais, variáveis coletadas de sensores e pontos de medição de processo.

No entanto, nem todos estes sinais são igualmente valiosos num sistema de monitoramento específico. Os sinais medidos contêm uma combinação de informações úteis, informações irrelevantes, bem como ruído.

Engenheiros tipicamente têm um número muito maior de sinais do que são realmente necessários. Se considerarmos cada tipo de sinal como uma característica, então a seleção da característica pode ser aplicada para identificar os sinais mais relevantes.

Os Engenheiros de Processo podem então usar estes sinais para determinar os fatores chave para o processo de produção. Isso poderá trazer benefícios para o processo, como redução do tempo e diminuição nos custos de produção.

Base de dados SECOM: 1567 exemplos e 591 atributos

IBM ANALYTICS EMPLOYEE ATTRITION & PERFORMANCE

Predict attrition of your valuable employees

- Base de dados

Descobrir os fatores que levam ao desgaste dos funcionários e explorar questões importantes, tais como "mostrar-me a influência da distância de casa em função do cargo e atrito" ou "comparar renda média mensal por educação e atrito". Este é um conjunto de dados fictícios criado por cientistas de dados da IBM.

IBM ANALYTICS EMPLOYEE ATTRITION & PERFORMANCE

Predict attrition of your valuable employees

- Base de dados

34 atributos:

Education: 1 'Below College' 2 'College' 3 'Bachelor' 4 'Master' 5 'Doctor'

EnvironmentSatisfaction 1 'Low' 2 'Medium' 3 'High' 4 'Very High'

JobInvolvement: 1 'Low' 2 'Medium' 3 'High' 4 'Very High'

JobSatisfaction: 1 'Low' 2 'Medium' 3 'High' 4 'Very High'

PerformanceRating: 1 'Low' 2 'Good' 3 'Excellent' 4 'Outstanding'

RelationshipSatisfaction: 1 'Low' 2 'Medium' 3 'High' 4 'Very High'

WorkLifeBalance: 1 'Bad' 2 'Good' 3 'Better' 4 'Best'

Gender, MaritalStatus, MonthlyIncome, Age, DistanceFromHome, OverTime, JobRole, YearsWithCurrentManager, Over18, etc...

IBM ANALYTICS EMPLOYEE ATTRITION & PERFORMANCE

Predict attrition of your valuable employees

- Base de dados

2 classes:

Attrition: Yes / No