

CLASSIFICAÇÃO



PÓS-GRADUAÇÃO EM CIÊNCIA DE DADOS

MANOELA KOHLER



prof.manoela@ica.ele.puc-rio.br



www.linkedin.com/in/manoelakohler

TÓPICOS

R

Análise exploratória

Pré-processamento

- Balanceamento
- *Outliers*
- *Missing values*
- Normalização
- Seleção de atributos (Filtros, *Wrappers*, PCA)

Associação:

- Apriori
- *FP-Growth*
- *Eclat*

Classificação:

- *Regressão logística*
- *Support Vector Machine (SVM)*
- Árvore de Decisão
- *Random Forest*
- ~~Redes Neurais~~
- *K nearest neighbors*

Regressão

- Regressão linear simples
- Regressão linear múltipla
- Regressão não linear simples
- Regressão não linear múltipla

Agrupamento

- Particionamento (K-means, K-medoids)
- Hierárquico (DIANA, AGNES)
- Densidade (DBSCAN)


Séries Temporais

- Naive
- Média Móvel
- Amortecimento exponencial
- Auto-regressivo integrados de média móvel
- Auto regressivo não linear

Recapitulação

ETAPAS DE UM PROJETO DE DATA MINING

ESQUEMA BÁSICO DE UM PROJETO DE DM



CLASSIFICAÇÃO


5 CLASSES DE PROBLEMAS DE DM



Machine Learning


Supervisionado

Classificação
Regressão
Previsão de séries temporais




Não Supervisionado

Agrupamento
Associação



Reforço

Aprendizado através da interação de agentes com um ambiente




SUPERVISIONADO

- Aproximador: função mapeia entradas e saída.


Classificação

Rótulo é categórico.



Regressão

Rótulo é contínuo.



Previsão de Séries


Rótulo é contínuo e dependente do tempo.



NÃO SUPERVISIONADO

Agrupamento

Descoberta de semelhanças e grupos entre registros.



Associação


Descoberta de relações entre variáveis.



SVM - Support Vector Machine

SVM NÃO LINEAR

Ideia geral: o espaço de atributos original pode – com alta probabilidade (Teorema de Cover) – ser mapeado para um espaço de atributos maior, onde os dados podem ser separados:



Árvores de Decisão

ÁRVORES DE DECISÃO – ID3

Predictors				Target
Outlook	Temp	Humidity	Windy	Play Golf
Rainy	Hot	High	False	No
Rainy	Hot	High	True	No
Overcast	Hot	High	False	Yes
Sunny	Mild	High	False	Yes
Sunny	Cool	Normal	False	Yes
Sunny	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Rainy	Mild	High	False	No
Rainy	Cool	Normal	False	Yes
Sunny	Mild	Normal	False	Yes
Rainy	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Sunny	Mild	High	True	No

Regras de
decisão


R_1 : IF (Outlook=Sunny) AND
(Windy=FALSE) THEN Play=Yes

R_2 : IF (Outlook=Sunny) AND
(Windy=TRUE) THEN Play=No

R_3 : IF (Outlook=Overcast) THEN
Play=Yes

R_4 : IF (Outlook=Rainy) AND
(Humidity=High) THEN Play=No

R_5 : IF (Outlook=Rain) AND
(Humidity=Normal) THEN
Play=Yes




COMITÊS

COMITÊS


Agregar múltiplos modelos treinados com o objetivo de melhorar a acurácia do modelo conjunto.

Intuição: simula o que fazemos quando combinamos conhecimento de especialistas em um processo de tomada de decisão.




COMITÊS - TÉCNICAS

COMITÊS: BAGGING X BOOSTING



COMITÊS: STACKING




COMITÊS: RMS

Random Subspace Method (RMS)

Similar ao Bagging, mas com aleatorização sobre os atributos.


Classificadores-base aprendem nos subespaços S de mesma dimensão.

Decisão final é por votação.



RANDOM FOREST

RANDOM FOREST: WORKFLOW



A proporção de votos diferentes da classe target em relação ao total de votos é o erro OOB (Out-Of-Bag estimate)

ESTUDOS DE CASO



Prêmio de 1 milhão de dólares

- Melhora na acurácia do sistema de recomendação de filmes da Netflix em 10%.
- Os melhores times combinaram diversos modelos e algoritmos em um comitê.

http://www.netflixprize.com/assets/GrandPrize2009_BPC_BigChaos.pdf

NETFLIX PRIZE

Tarefa de aprendizado supervisionado

- Dados de treinamento são formados por um conjunto de usuários e as avaliações dos filmes (1,2,3,4,5 estrelas) feitas por esses usuários;
- Construir um classificador que dado um usuário e um filme não avaliado, classifique corretamente aquele filme como 1, 2, 3, 4, ou 5 estrelas;
- Prêmio de \$1 milhão para 10% em melhora na acurácia em relação ao modelo atual.

ESTUDOS DE CASO

Trabalho

KNN






KNN

1. Determinar o valor de K , ou número de vizinhos
2. Calcular a distância entre cada par de registros
3. Determinar quais são os K registros (vizinhos) mais próximos do novo registro
4. Dentre esses K vizinhos, contar o número de vizinhos em cada classe
5. O novo registro vai ser da classe majoritária entre os vizinhos mais próximos


KNN

Passo 1: Determinar o valor de K, ou número de vizinhos **K = 5**




KNN

Passo 2: Calcular a distância entre cada par de registros




KNN

Passo 3: Determinar quais são os 5 vizinhos mais próximos (distância euclidiana) do novo registro




KNN

Passo 4: Dentre os 5 vizinhos, contar o número de vizinhos em cada classe




KNN

Passo 5: O novo registro vai ser da classe majoritária entre os vizinhos mais próximos



KNN

Passo 5: O novo registro vai ser da classe majoritária entre os vizinhos mais próximos




KNN

A classe do novo padrão é igual ao da K maioria mais próxima.

Pendências:


- Qual tipo de distância usar?
- Qual valor de K?
- Como Desempatar?

DISTÂNCIA



$$\begin{aligned} d(x_j, y_j) &= \sqrt{(70 - 80)^2 + (165 - 173)^2} = \\ &= \sqrt{(10)^2 + (8)^2} = \sqrt{100 + 64} = \\ &= \sqrt{164} = 12.81 \end{aligned}$$


DISTÂNCIA



■ **Manhattan:**

$$\begin{aligned} d(x_j, y_j) &= |70 - 80| + |165 - 173| = \\ &= |-10| + |-8| = 10 + 8 = 18 \end{aligned}$$

DISTÂNCIA



■ Minkowski:

$$d(x_j, y_j) = \max(|70-80|, |165-173|) = \max(|-10|, |-8|) = \max(10, 8) = 10$$

KNN

A classe do novo padrão é igual ao da K maioria mais Próxima.

Pendências:

- Qual tipo de distância usar?
- Qual valor de K?
- Como Desempatar?

Escolha experimental

KNN


A classe do novo padrão é igual ao da K maioria mais Próxima.

Pendências:

- Qual tipo de distância usar?
- Qual valor de K?
- Como Desempatar?

Escolha aleatória
Escolha aleatória ponderada
Classe mais próxima

DESEMPATE




Supondo $K = 4$

Escolha Aleatória:

“Jogue uma moeda honesta”: caso saia cara, escolha a classe vermelha, caso saia coroa, escolha a classe azul.

DESEMPATE




Supondo $K = 4$

Escolha Aleatória Ponderada:

“Jogue uma moeda desonesta”: Dê mais chance à classe que está relacionada a classe que possua mais padrões.

DESEMPATE



Supondo $K = 4$

Classe mais próxima:

Selecione a classe cuja distância é menor.

ESTUDOS DE CASO

CÂNCER DE MAMA


University of Wisconsin, Clinical Sciences Center

30 atributos + classe + id:

- Raio: distância media do centro à pontos no perímetro do tumor;
- Textura: desvio padrão dos valores em escala de cinza;
- Perímetro;
- Área;
- Etc...

569 instâncias: 357 Benignas / 212 Malignas

<https://www.kaggle.com/uciml/breast-cancer-wisconsin-data/home>




CÂNCER DE MAMA

1. Criem um modelo KNN para classificar os tumores em maligno ou benigno na ferramenta de preferência (Python e/ou Rapidminer). Arquivo 'breastCancer.csv'
2. Faça um pós processamento sendo conservador: somente inferências com 80% de probabilidade serão classificadas como benigno.
3. Ao terminar tentem fazer os mesmo para a base 'breastCancer_3classes.csv'. Esta base tem uma classe a mais: a classe 'Suspeito'.

REGRESSÃO LOGÍSTICA

REGRESSÃO LINEAR SIMPLES

Simple Linear Regression:





$$y = b_0 + b_1 * x$$





$$\text{Salary} = b_0 + b_1 * \text{Experience}$$


REGRESSÃO LOGÍSTICA




REGRESSÃO LOGÍSTICA



REGRESSÃO LOGÍSTICA




REGRESSÃO LOGÍSTICA




REGRESSÃO LOGÍSTICA

Pensando em probabilidades, esses 'pedaços' não fazem mais sentido.

Poderíamos alterar para modelar melhor o problema.



REGRESSÃO LOGÍSTICA






REGRESSÃO LOGÍSTICA

Regressão Linear → Aplica sigmoidal → Regressão Logística


$$y = b_0 + b_1x_1 \quad \Rightarrow \quad f(a) = \frac{1}{1 + e^{-a}}$$

$$y' = f(y) = \frac{1}{1 + e^{-(b_0 + b_1x_1)}}$$


REGRESSÃO LOGÍSTICA




REGRESSÃO LOGÍSTICA




REGRESSÃO LOGÍSTICA



REGRESSÃO LOGÍSTICA



REGRESSÃO LOGÍSTICA - INFERÊNCIA



ESTUDOS DE CASO

CÂNCER DE MAMA

University of Wisconsin, Clinical Sciences Center

30 atributos + classe + id:

- Raio: distância media do centro à pontos no perímetro do tumor;
- Textura: desvio padrão dos valores em escala de cinza;
- Perímetro;
- Área;
- Etc...

569 instâncias: 357 Benignas / 212 Malignas

<https://www.kaggle.com/uciml/breast-cancer-wisconsin-data/home>

