

# ASSOCIAÇÃO



PÓS-GRADUAÇÃO EM CIÊNCIA DE DADOS

MANOELA KOHLER



[prof.manoela@ica.ele.puc-rio.br](mailto:prof.manoela@ica.ele.puc-rio.br)



[www.linkedin.com/in/manoelakohler](https://www.linkedin.com/in/manoelakohler)

# TÓPICOS

## Análise exploratória

### Pré-processamento

- Balanceamento
- *Outliers*
- *Missing values*
- Normalização
- Seleção de atributos (Filtros, Wrappers, PCA)

### Associação:

- *Apriori*
- *FP-Growth*
- *Eclat*

## Classificação:

- Regressão logística
- *Support Vector Machine (SVM)*
- Árvores de Decisão
- *Random Forest*
- ~~Redes Neurais~~
- *K nearest neighbors*

## Regressão

- Regressão linear simples
- Regressão linear múltipla
- Regressão não linear simples
- Regressão não linear múltipla

## Agrupamento

- Particionamento (K-means, K-medoids)
- Hierárquico (DIANA, AGNES)
- Densidade (DBSCAN)

## Séries Temporais


- Naive
- Média Móvel
- Amortecimento exponencial
- Auto-regressivo integrados de média móvel
- Auto regressivo não linear

# Trabalho

# Recapitulação

# ETAPAS DE UM PROJETO DE DATA MINING

# ESQUEMA BÁSICO DE UM PROJETO DE DM




# CLASSIFICAÇÃO

# SVM - Support Vector Machine

# SVM

Ideia geral: o espaço de atributos original sempre pode ser mapeado para um espaço de atributos maior, onde os dados podem ser separados:



# Árvores de Decisão

# ÁRVORES DE DECISÃO – ID3

| Predictors |      |          |       | Target    |
|------------|------|----------|-------|-----------|
| Outlook    | Temp | Humidity | Windy | Play Golf |
| Rainy      | Hot  | High     | False | No        |
| Rainy      | Hot  | High     | True  | No        |
| Overcast   | Hot  | High     | False | Yes       |
| Sunny      | Mild | High     | False | Yes       |
| Sunny      | Cool | Normal   | False | Yes       |
| Sunny      | Cool | Normal   | True  | No        |
| Overcast   | Cool | Normal   | True  | Yes       |
| Rainy      | Mild | High     | False | No        |
| Rainy      | Cool | Normal   | False | Yes       |
| Sunny      | Mild | Normal   | False | Yes       |
| Rainy      | Mild | Normal   | True  | Yes       |
| Overcast   | Mild | High     | True  | Yes       |
| Overcast   | Hot  | Normal   | False | Yes       |
| Sunny      | Mild | High     | True  | No        |

Regras de  
decisão


$R_1$ : IF (Outlook=Sunny) AND  
(Windy=FALSE) THEN Play=Yes

$R_2$ : IF (Outlook=Sunny) AND  
(Windy=TRUE) THEN Play=No

$R_3$ : IF (Outlook=Overcast) THEN  
Play=Yes

$R_4$ : IF (Outlook=Rainy) AND  
(Humidity=High) THEN Play=No

$R_5$ : IF (Outlook=Rain) AND  
(Humidity=Normal) THEN  
Play=Yes




COMITÊS

# COMITÊS


Agregar múltiplos modelos treinados com o objetivo de melhorar a acurácia do modelo conjunto.

Intuição: simula o que fazemos quando combinamos conhecimento de especialistas em um processo de tomada de decisão.



# RANDOM FOREST


# RANDOM FOREST: WORKFLOW



A proporção de votos diferentes da classe target em relação ao total de votos é o erro OOB (Out-Of-Bag estimate)




KNN

# KNN



# REGRESSÃO LOGÍSTICA

# REGRESSÃO LOGÍSTICA




ASSOCIAÇÃO

# Machine Learning


## Supervisionado

Classificação  
Regressão  
Previsão de séries temporais




## Não Supervisionado

Agrupamento  
Associação



## Reforço

Aprendizado através da interação de agentes com um ambiente




# SUPERVISIONADO

- Aproximador: função mapeia entradas e saída.


## Classificação

Rótulo é categórico.



## Regressão

Rótulo é contínuo.



## Previsão de Séries


Rótulo é contínuo e dependente do tempo.



# NÃO SUPERVISIONADO

## Agrupamento

Descoberta de semelhanças e grupos entre registros.



## Associação

Descoberta de relações entre variáveis.





# PROBLEMA DE ASSOCIAÇÃO

- Considere uma loja com 3 produtos: TV, Tablet e Smartphone
- Dado um novo cliente:
  - **Pergunta 1:** Qual produto oferecer?
  - TV?
  - Tablet?
  - Smartphone?
- **Vamos buscar a resposta via análise do histórico**



# PROBLEMA DE ASSOCIAÇÃO

- Considere um grupo de clientes que observaram/adquiriram determinados produtos (itens):



| id    | TV | Tablet | Smartphone |
|-------|----|--------|------------|
| A     | 0  | 1      | 1          |
| B     | 1  | 1      | 0          |
| C     | 0  | 0      | 1          |
| D     | 0  | 0      | 1          |
| E     | 1  | 1      | 0          |
| F     | 0  | 1      | 1          |
| G     | 1  | 1      | 0          |
| Total | 3  | 5      | 4          |

# PROBLEMA DE ASSOCIAÇÃO

- Parece razoável propor ao novo cliente, a ordem:
  - Tablet (5/7 acessos)
  - Smartphone (4/7 acessos)
  - TV (3/7 acessos)
- Pergunta 2: Dado que o cliente visualizou o Tablet,  
qual o **próximo item** a se oferecer/mostrar?

# PROBLEMA DE ASSOCIAÇÃO

- Parece razoável propor ao novo cliente, a ordem:
  - Tablet (5/7 acessos)
  - Smartphone (4/7 acessos)
  - TV (3/7 acessos)
- **Pergunta 2:** Dado que o cliente visualizou o Tablet,  
qual o **próximo item** a se oferecer/mostrar?

# PROBLEMA DE ASSOCIAÇÃO

- **Pergunta 2:** Verificando todos as transações que acessaram o Tablet:

| id       | TV       | Tablet   | Smartphone |
|----------|----------|----------|------------|
| <b>A</b> | <b>0</b> | <b>1</b> | <b>1</b>   |
| <b>B</b> | <b>1</b> | <b>1</b> | <b>0</b>   |
| C        | 0        | 0        | 1          |
| D        | 0        | 0        | 1          |
| <b>E</b> | <b>1</b> | <b>1</b> | <b>0</b>   |
| <b>F</b> | <b>0</b> | <b>1</b> | <b>1</b>   |
| <b>G</b> | <b>1</b> | <b>1</b> | <b>0</b>   |
| Total    | 3        | 5        | 4          |

- Das 5 pessoas que acessaram Tablet, 3 também acessaram TV
- Das 5 pessoas que acessaram Tablet, 2 também acessaram Smartphone
- **Moral:** “Se Acesso é Tablet, então Acesso TV”

# PROBLEMA DE ASSOCIAÇÃO: DEFINIÇÃO

| Transação | Itens |     |     | Atributos |     |          |
|-----------|-------|-----|-----|-----------|-----|----------|
| $x_1$     | 1     | ... | 0   | $x_{11}$  | ... | $x_{1J}$ |
| $x_2$     | 1     | ... | 1   | $x_{21}$  | ... | $x_{2J}$ |
| $x_3$     | 0     | ... | 1   | $x_{31}$  | ... | $x_{3J}$ |
| ...       | ...   | ... | ... | ...       | ... | ...      |
| $x_i$     | 0     | ... | 1   | $x_{i1}$  | ... | $x_{iJ}$ |
| ...       | ...   | ... | ... | ...       | ... | ...      |
| $x_n$     | 1     | ... | 1   | $x_{n1}$  | ... | $x_{nJ}$ |

- **Formalmente:**

- Um conjunto de  $n$  Transações
- Cada Transação é composta de acesso a um conjunto de **Itens**
- Cada transação pode ou não conter um conjunto de **Atributos**
- **Objetivo:** Construir uma Base de Regras que forme uma **Cesta de Itens** cujo acesso estão Associados

# PROBLEMA DE ASSOCIAÇÃO: EXEMPLOS

Televentas 24h: ligue 4003-2000   Atendimento   Meus pedidos   Minha conta   Cartão Submarino: peça já o seu

**sub.com**   Olá, Visitante   Entre Cadastre-se       Wow!  

Os produtos que você curte. O melhor serviço da internet.

**Navegue pelas lojas**   Moda Inverno   Cartão Submarino   Oferta Wow   Páscoa   Regras do Site

Você está em: Informática > Tablets e iPad > **Tablets**   Compra segura Submarino

**Tablet LG G Pad V700 16GB Wi-Fi Tela 10" Android 4.4 Qualcomm Quad Core 1.2 GHz - Preto** (Cód. 120187851)

★★★★★ (2 avaliações) [avaliar este produto](#)

Vendido e entregue por **Submarino**   Produto em estoque

**10%OFF no boleto**

De: R\$ 1.090,00

**R\$ 799,00** (27% de desconto)

10x de R\$ 79,90 sem juros   [Ver parcelas](#)

R\$ 719,10 (10% de desconto) no boleto bancário

**Cartão Submarino: 1x de R\$ 719,10**

Ou R\$ 799,00 Em até 12x de R\$ 66,58 sem juros

Ganhe até 2.307 Léguas   [Ver parcelas](#)

**Frete e prazo:**

**OFICINA DOS BITS** **R\$ 922,90 em até 12x**

# PROBLEMA DE ASSOCIAÇÃO: EXEMPLOS

Quem viu este produto acabou comprando

| 46% compraram                                                                      | 14% compraram                                                                       | 9% compraram                                                                        | 5% compraram                                                                        |
|------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|
|  |  |  |  |
| Tablet LG G Pad V700 16GB Wi-Fi<br>Tela 10" Android...<br>★★★★★ (1)                | Tablet LG G Pad V700 16GB Wi-Fi<br>Tela 10" Android...<br>★★★★★ (14)                | Tablet LG G Pad V700 16GB Wi-Fi<br>Tela 10" Android...<br>★★★★★ (24)                | Tablet Samsung Galaxy Tab 4<br>T530N 16GB Wi-Fi Tela...<br>★★★★★ (23)               |
| De: R\$ 1.099,00<br><b>R\$ 799,00</b><br>ou 10x de R\$ 79,90 sem juros             | De: R\$ 999,00<br><b>R\$ 799,00</b><br>ou 10x de R\$ 79,90 sem juros                | De: R\$ 1.099,00<br><b>R\$ 799,00</b><br>ou 10x de R\$ 79,90 sem juros              | De: R\$ 1.299,00<br><b>R\$ 1.149,00</b><br>ou 10x de R\$ 114,90 sem juros           |
| ou em 12x de R\$ 66,58 sem juros no Cartão Submarino                               | ou em 12x de R\$ 66,58 sem juros no Cartão Submarino                                | ou em 12x de R\$ 66,58 sem juros no Cartão Submarino                                | ou em 12x de R\$ 95,75 sem juros no Cartão Submarino                                |
| Frete grátis                                                                       | Frete grátis                                                                        | Frete grátis                                                                        | Frete grátis                                                                        |
| 10% OFF na boleto                                                                  | 10% OFF na boleto                                                                   | 10% OFF na boleto                                                                   | 10% OFF na boleto                                                                   |
| + LG                                                                               | + LG                                                                                | + LG                                                                                | + Samsung                                                                           |
| Veja em outros locais                                                              |                                                                                     |                                                                                     | Veja em outros locais                                                               |

Quem viu este produto viu também

|                                                                                     |                                                                                      |                                                                                      |                                                                                      |
|-------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|
|  |  |  |  |
| Tablet Lenovo Yoga 16GB Wi-Fi<br>Tela IPS 10.1"...<br>★★★★★ (12)                    | Tablet Intel TM105A 16GB Wi-Fi<br>Tela TFT 10.1"...<br>★★★★★ (1)                     | Tablet LG G Pad V480 16GB Wi-Fi<br>Tela 8" Android...<br>★★★★★ (17)                  | Tablet LG G Pad V400 8GB Wi-Fi<br>Tela IPS WXGA 7..."<br>★★★★★ (12)                  |
| De: R\$ 899,00<br><b>R\$ 809,10</b><br>ou 10x de R\$ 80,91 sem juros                | De: R\$ 799,00<br><b>R\$ 719,10</b><br>ou 10x de R\$ 71,91 sem juros                 | De: R\$ 799,00<br><b>R\$ 799,00</b><br>ou 10x de R\$ 79,90 sem juros                 | De: R\$ 699,00<br><b>R\$ 479,00</b><br>ou 10x de R\$ 47,90 sem juros                 |
| ou em 12x de R\$ 67,42 sem juros no Cartão Submarino                                | ou em 12x de R\$ 59,93 sem juros no Cartão Submarino                                 | ou em 12x de R\$ 66,58 sem juros no Cartão Submarino                                 | ou em 12x de R\$ 39,92 sem juros no Cartão Submarino                                 |
| Frete grátis                                                                        | Frete grátis                                                                         | Frete grátis                                                                         | Frete grátis                                                                         |
| 10% OFF na boleto                                                                   | 10% OFF na boleto                                                                    | 10% OFF na boleto                                                                    | 10% OFF na boleto                                                                    |
| + Lenovo                                                                            | + Intel                                                                              | + LG                                                                                 | + LG                                                                                 |

# PROBLEMA DE ASSOCIAÇÃO: EXEMPLOS

## More Items to Consider

| You viewed                                                                        | Customers who viewed this also viewed                                             |                                                                                    |                                                                                     |                                                                                     |                                                                                     |                                                                                     |
|-----------------------------------------------------------------------------------|-----------------------------------------------------------------------------------|------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|
|  |  |  |  |  |  |  |
| KHOMO ® DUAL CASE Green Smart Cover...<br>★★★★☆ (154)<br>\$49.99 \$22.99          | KHOMO ® DUAL CASE: Purple Smart Cover...<br>★★★★☆ (49)<br>\$49.99 \$22.99         | KHOMO ® DUAL CASE Red Smart Cover...<br>★★★★☆ (68)<br>\$49.99 \$19.85              | CaseCrown Bold Standby Case for iPad...<br>★★★★☆ (1,587)<br>\$36.99 \$20.21         | KHOMO ® DUAL CASE: Blue Smart Cover...<br>★★★★☆ (83)<br>\$49.99 \$19.89             | GMYLE Red Folding Cover Folio Slim...<br>★★★★☆ (78)<br>\$7.99                       | KHOMO ® DUAL Black Case Polyurethane...<br>★★★★☆ (217)<br>\$49.99 \$19.85           |

[View or edit your browsing history](#)

## Related Items You've Viewed

| You viewed                                                                         | Customers who viewed this also viewed                                              |                                                                                                                |                                                                                                                 |                                                                                      |                                                                                      |                                                                                                                   |
|------------------------------------------------------------------------------------|------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------|
|  |  |  |  |  |  |  |
| Kindle Fire 7\", LCD Display, Wi-Fi, 8...<br>Amazon<br>★★★★☆ (1,972)<br>\$159.00   | Amazon Kindle PowerFast for...<br>★★★★☆ (1,272)<br>\$19.99                         | Kindle Fire HD 7\", Dolby Audio...<br>Amazon<br>★★★★☆ (4,615)<br>\$199.00                                      | Kindle Fire HD 8.9\", Dolby Audio...<br>Amazon<br>★★★★☆ (1,253)<br>\$299.00                                     | Kindle, 6\" E Ink Display, Wi-Fi...<br>Amazon<br>★★★★☆ (1,270)<br>\$69.00            | Kindle Paperwhite, 6\" High Resolution...<br>Amazon<br>★★★★☆ (3,173)<br>\$119.00     | Kindle Fire HD 8.9\" 4G LTE Wireless...<br>Amazon<br>★★★★☆ (1,252)<br>\$499.00                                    |

[View or edit your browsing history](#)

# REGRAS DE ASSOCIAÇÃO: CONCEITOS

- Uma **Regra** é uma expressão simbólica representada por:
  - Termo Antecedente, Premissa ou Lado Esquerdo (LHS)
  - Termo Consequente ou Lado Direito (RHS)
- **Exemplo:** *“Se Acesso é Tablet, então Acesso é TV”*  
*Antecedente* *Consequente*

# REGRAS DE ASSOCIAÇÃO: CONCEITOS

- A parte **Antecedente** pode ser formada por uma Conjunção, usando o termo linguístico e
- **Exemplo:**
  - “Se Acesso é Tablet e Acesso é TV” (1 conjunção)
  - “Se Acesso é Tablet e Acesso é TV e Acesso é Smartphone” (2 conjunções)
- **Observação:** A ordem dos fatores na premissa da regra não altera o seu resultado final

# REGRAS DE ASSOCIAÇÃO: CONCEITOS

- Na tabela, o Antecedente “Se Acesso é Tablet” representa:

| id    | Tablet |
|-------|--------|
| A     | 1      |
| B     | 1      |
| C     | 0      |
| D     | 0      |
| E     | 1      |
| F     | 1      |
| G     | 1      |
| Total | 5      |

- Ou de outra forma:

| Item   | id                | Total |
|--------|-------------------|-------|
| Tablet | {A, B, E, F e G } | 5     |

# REGRAS DE ASSOCIAÇÃO: CONCEITOS

- Na tabela, o Antecedente: “Se Acesso é Tablet e Acesso é TV”, representa

| id    | Tablet | TV | Tablet e TV |
|-------|--------|----|-------------|
| A     | 1      | 0  | 0           |
| B     | 1      | 1  | 1           |
| C     | 0      | 0  | 0           |
| D     | 0      | 0  | 0           |
| E     | 1      | 1  | 1           |
| F     | 1      | 0  | 0           |
| G     | 1      | 1  | 1           |
| Total | 5      | 3  | 3           |

- Ou de outra forma:

| Item        | id                | Total |
|-------------|-------------------|-------|
| Tablet      | {A, B, E, F e G } | 5     |
| TV          | {B, E e G }       | 3     |
| Tablet e TV | {B, E e G }       | 3     |

- Portanto, a Conjunção e representa uma Intersecção entre conjuntos (colunas).


# REGRAS DE ASSOCIAÇÃO: CONCEITOS

- **Observação:** note que a Conjunção reduz o número de 1's ou de id's que acessaram:

| Item        | id                | Total |
|-------------|-------------------|-------|
| Tablet      | {A, B, E, F e G } | 5     |
| TV          | {B, E e G }       | 3     |
| Tablet e TV | {B, E e G }       | 3     |

- Logo:
  - # Tablet = 5
  - # TV = 3
  - # Tablet e TV = 3
- A operação de intersecção tende sempre a reduzir o número de id's

# REGRAS DE ASSOCIAÇÃO: CONCEITOS



# REGRAS DE ASSOCIAÇÃO: MÉTRICAS

- Há duas métricas relevantes para o processo de Mineração de Regras de Associação:
  - Suporte
  - Confiança ou Certeza
- As métricas possibilitam gerar um conjunto compacto e que atenda a requisitos mínimos de qualidade

# REGRAS DE ASSOCIAÇÃO: SUPORTE

- **Suporte:** Verifica a frequência de transações que são cobertas pela premissa de regra.
- Exemplo:

| id      | Tablet | Tablet e TV |
|---------|--------|-------------|
| A       | 1      | 0           |
| B       | 1      | 1           |
| C       | 0      | 0           |
| D       | 0      | 0           |
| E       | 1      | 1           |
| F       | 1      | 0           |
| G       | 1      | 1           |
| Total   | 5      | 3           |
| Suporte | 0,71   | 0,43        |

- Duas Premissas:

- $Prem_1 = \text{"Se Acesso é Tablet"}$

- $Prem_2 = \text{"Se Acesso é Tablet e TV"}$

- Suporte das Premissas:

- $Sup(Prem_1) = \frac{\#1's}{\#id's} = \frac{5}{7}$

- $Sup(Prem_2) = \frac{\#1's}{\#id's} = \frac{3}{7}$

# REGRAS DE ASSOCIAÇÃO: CONFIANÇA

- **Confiança:** Verifica a frequência conjunta de transações que são cobertas tanto pela premissa, quanto pelo consequente da regra.
- Exemplo:

| id        | Tablet | Tablet $\Rightarrow$ TV |
|-----------|--------|-------------------------|
| A         | 1      | 0                       |
| B         | 1      | 1                       |
| C         | 0      | 0                       |
| D         | 0      | 0                       |
| E         | 1      | 1                       |
| F         | 1      | 0                       |
| G         | 1      | 1                       |
| Total     | 5      | 3                       |
| Confiança | -      | 0,6                     |

- Uma Regra:

- $R_1 =$  "Se Acesso é Tablet, então Acesso é TV"

- Confiança da Regra:

- $Conf(R_1) = \frac{Sup(Prem_1 \cap Cons_1)}{Sup(Prem_1)} = \frac{3}{5} = 0,6$

# APRIORI

# ALGORITMO APRIORI - IDEIA

- Introdução:

- O algoritmo Apriori foi proposto por Agrawal et al. (1993)
- Este algoritmo está presente em diversos softwares comerciais e públicos
- É de fácil uso e é amplamente usado em diversos trabalhos

- Conceitos Básicos:

- Extraia um conjunto de regras a partir da **conjunção de itens** mais frequentes na base de dados, até que **alguns critérios de parada** sejam atendidos:
  - Tamanho máximo da regra
  - Suporte mínimo da premissa
  - Confiança mínima da regra
  - ...

# ALGORITMO APRIORI - IDEIA

- Introdução:

- O algoritmo Apriori foi proposto por Agrawal et al. (1993)
- Este algoritmo está presente em diversos softwares comerciais e públicos
- É de fácil uso e é amplamente usado em diversos trabalhos

- Conceitos Básicos:

- Extraia um conjunto de regras a partir da **conjunção de itens** mais frequentes na base de dados, até que **alguns critérios de parada** sejam atendidos:
  - Tamanho máximo da regra
  - Suporte mínimo da premissa
  - Confiança mínima da regra
  - ...

# ALGORITMO APRIORI - EXEMPLO

- Considere o exemplo até agora usado:

| id    | TV | Tablet | Smartphone |
|-------|----|--------|------------|
| A     | 0  | 1      | 1          |
| B     | 1  | 1      | 0          |
| C     | 0  | 0      | 1          |
| D     | 0  | 0      | 1          |
| E     | 1  | 1      | 0          |
| F     | 0  | 1      | 1          |
| G     | 1  | 1      | 0          |
| Total | 3  | 5      | 4          |

- **Passo 1:** defina os parâmetros usados como base para extração das regras de associação:
  - Tamanho máximo da regra = 2
  - Suporte mínimo da premissa =  $1/7$
  - Confiança mínima da regra =  $2/7$

# ALGORITMO APRIORI - EXEMPLO

- **Passo 2:** Gerar as primeiras premissas e calcular as métricas:

| id    | TV | Tablet | Smartphone |
|-------|----|--------|------------|
| A     | 0  | 1      | 1          |
| B     | 1  | 1      | 0          |
| C     | 0  | 0      | 1          |
| D     | 0  | 0      | 1          |
| E     | 1  | 1      | 0          |
| F     | 0  | 1      | 1          |
| G     | 1  | 1      | 0          |
| Total | 3  | 5      | 4          |

- Premissas:

- $Prem_1 = \text{"Se Acesso é TV"}$
- $Prem_2 = \text{"Se Acesso é Tablet"}$
- $Prem_3 = \text{"Se Acesso é Smartphone"}$

- Suporte:

- $Sup(Prem_1) = 3/7$
- $Sup(Prem_2) = 5/7$
- $Sup(Prem_3) = 4/7$

- Todas são viáveis!

# ALGORITMO APRIORI - EXEMPLO

## ■ Regras:

- **Passo 3:** Gerar as regras e calcular as métricas:

| id    | TV | Tablet | Smartphone |
|-------|----|--------|------------|
| A     | 0  | 1      | 1          |
| B     | 1  | 1      | 0          |
| C     | 0  | 0      | 1          |
| D     | 0  | 0      | 1          |
| E     | 1  | 1      | 0          |
| F     | 0  | 1      | 1          |
| G     | 1  | 1      | 0          |
| Total | 3  | 5      | 4          |

- $R_1 = \text{"Se Acesso é TV, então Acesso é Tablet"}$
- $R_2 = \text{"Se Acesso é TV, então Acesso é Smartphone"}$
- $R_3 = \text{"Se Acesso é Tablet, então Acesso é TV"}$
- $R_4 = \text{"Se Acesso é Tablet, então Acesso é Smartphone"}$
- $R_5 = \text{"Se Acesso é Smartphone, então Acesso é TV"}$
- $R_6 = \text{"Se Acesso é Smartphone, então Acesso é Tablet"}$

# ALGORITMO APRIORI - EXEMPLO

- **Passo 3:** Gerar as regras e calcular as métricas:

| id    | TV | Tablet | Smartphone |
|-------|----|--------|------------|
| A     | 0  | 1      | 1          |
| B     | 1  | 1      | 0          |
| C     | 0  | 0      | 1          |
| D     | 0  | 0      | 1          |
| E     | 1  | 1      | 0          |
| F     | 0  | 1      | 1          |
| G     | 1  | 1      | 0          |
| Total | 3  | 5      | 4          |

- **Confiança:**

- $Conf(R_1) = 3/3$

- $Conf(R_2) = 0/3$

- $Conf(R_3) = 3/5$

- $Conf(R_4) = 2/5$

- $Conf(R_5) = 0/4$

- $Conf(R_6) = 2/4$

- Corte as regras  $R_2$  e  $R_5$

# ALGORITMO APRIORI - EXEMPLO

- **Passo 4:** Refaça o passo 2 e 3 até o critério de parada:

| id    | TV | Tablet | Smartphone |
|-------|----|--------|------------|
| A     | 0  | 1      | 1          |
| B     | 1  | 1      | 0          |
| C     | 0  | 0      | 1          |
| D     | 0  | 0      | 1          |
| E     | 1  | 1      | 0          |
| F     | 0  | 1      | 1          |
| G     | 1  | 1      | 0          |
| Total | 3  | 5      | 4          |

- Novas Premissas:

- $Prem_4 =$  "Se Acesso é TV e Tablet"
- $Prem_5 =$  "Se Acesso é TV e Smartphone"
- $Prem_6 =$  "Se Acesso é Tablet e TV"
- $Prem_7 =$  "Se Acesso é Tablet e Smartphone"
- $Prem_8 =$  "Se Acesso é Smartphone e TV"
- $Prem_9 =$  "Se Acesso é Smartphone e Tablet"

# ALGORITMO APRIORI - EXEMPLO

- **Passo 4:** Refaça o passo 2 e 3 até o critério de parada:

| id    | TV | Tablet | Smartphone |
|-------|----|--------|------------|
| A     | 0  | 1      | 1          |
| B     | 1  | 1      | 0          |
| C     | 0  | 0      | 1          |
| D     | 0  | 0      | 1          |
| E     | 1  | 1      | 0          |
| F     | 0  | 1      | 1          |
| G     | 1  | 1      | 0          |
| Total | 3  | 5      | 4          |

- Suporte:

- $Sup(Prem_4) = 3/7$
- $Sup(Prem_5) = 0/7$
- $Sup(Prem_6) = 3/7$
- $Sup(Prem_7) = 2/7$
- $Sup(Prem_8) = 0/7$
- $Sup(Prem_9) = 2/7$

- Remova  $Prem_5$  e  $Prem_8$

# ALGORITMO APRIORI - EXEMPLO

- **Passo 4:** Refaça o passo 2 e 3 até o critério de parada:

| id    | TV | Tablet | Smartphone |
|-------|----|--------|------------|
| A     | 0  | 1      | 1          |
| B     | 1  | 1      | 0          |
| C     | 0  | 0      | 1          |
| D     | 0  | 0      | 1          |
| E     | 1  | 1      | 0          |
| F     | 0  | 1      | 1          |
| G     | 1  | 1      | 0          |
| Total | 3  | 5      | 4          |

- **Novas Regras**

- $R_7 = \text{"Se Acesso é TV e Tablet, então é Smartphone"}$
- $R_8 = \text{"Se Acesso é Tablet e TV, então é Smartphone"}$
- $R_9 = \text{"Se Acesso é Tablet e Smartphone, então é TV"}$
- $R_{10} = \text{"Se Acesso é Smartphone e Tablet, então é TV"}$
- Claramente, todas são inviáveis, pois  $\{Smartphone\} \cap \{TV\} = \emptyset$

# ALGORITMO APRIORI - EXEMPLO

- **Passo 5:** Retorne as regras geradas

- $R_1 =$  “Se Acesso é TV, então Acesso é Tablet”

- $R_3 =$  “Se Acesso é Tablet, então Acesso é TV”

- $R_4 =$  “Se Acesso é Tablet, então Acesso é Smartphone”

- $R_6 =$  “Se Acesso é Smartphone, então Acesso é Tablet”


- The end

DICAS

# PREPARAR A BASE

Base deve ser transformada em uma matriz esparsa para que possa ser apresentada ao algoritmo de associação!

| id |              |       |          |
|----|--------------|-------|----------|
| 1  | Ovo          | Leite | Manteiga |
| 2  | Manteiga     |       |          |
| 3  | Chocolate    |       |          |
| 4  | Água         |       |          |
| 5  | Refrigerante | Água  |          |
| 6  | Leite        | Maça  |          |




| id | Ovo | Leite | Manteiga | Chocolate | Água | Refrigerante | Maça |
|----|-----|-------|----------|-----------|------|--------------|------|
| 1  |     |       |          |           |      |              |      |
| 2  |     |       |          |           |      |              |      |
| 3  |     |       |          |           |      |              |      |
| 4  |     |       |          |           |      |              |      |
| 5  |     |       |          |           |      |              |      |
| 6  |     |       |          |           |      |              |      |

# PREPARAR A BASE

Base deve ser transformada em uma matriz esparsa para que possa ser apresentada ao algoritmo de associação!

| id |              |       |          |
|----|--------------|-------|----------|
| 1  | Ovo          | Leite | Manteiga |
| 2  | Manteiga     |       |          |
| 3  | Chocolate    |       |          |
| 4  | Água         |       |          |
| 5  | Refrigerante | Água  |          |
| 6  | Leite        | Maça  |          |



| id | Ovo | Leite | Manteiga | Chocolate | Água | Refrigerante | Maça |
|----|-----|-------|----------|-----------|------|--------------|------|
| 1  | 1   | 1     | 1        | 0         | 0    | 0            | 0    |
| 2  | 0   | 0     | 1        | 0         | 0    | 0            | 0    |
| 3  | 0   | 0     | 0        | 1         | 0    | 0            | 0    |
| 4  | 0   | 0     | 0        | 0         | 1    | 0            | 0    |
| 5  | 0   | 0     | 0        | 0         | 1    | 1            | 0    |
| 6  | 0   | 1     | 0        | 0         | 0    | 0            | 1    |

Local Repository/processes/aula05\_print\* - RapidMiner Studio Educational 7.5.001 @ ICA-080

File Edit Process View Connections Cloud Settings Extensions

Views: Design Results

Need help?

Repository

Add Data

- Aula03\_Full (manuela - v1, 5/11/17 11:52 AM - 31 KB)
- Aula03\_Full\_2 (manuela - v1, 5/11/17 5:05 PM - 31 KB)
- Aula03\_Full\_R\_TESTE (manuela - v1, 5/11/17 11:52 AM - 31 KB)
- Aula04 (manuela - v1, 5/23/17 7:01 PM - 55 KB)
- Aula04\_Print (manuela - v1, 5/25/17 2:33 PM - 42 KB)
- Aula05\_1 (manuela - v1, 5/31/17 10:59 AM - 13 KB)
- Aula05\_2 (manuela - v1, 5/30/17 5:03 PM - 9 KB)
- aula05\_print (manuela - v1, 5/31/17 12:56 PM - 1 KB)
- IBM\_AttributeSelection (manuela - v1, 5/3/17 10:59 AM - 13 KB)
- IBM\_AttributeSelection\_2 (manuela - v1, 5/4/17 12:12 PM - 13 KB)
- IBM\_IG\_WeightSelection (manuela - v1, 5/4/17 12:12 PM - 13 KB)
- IBM\_Limpeza (manuela - v1, 5/2/17 4:07 PM - 8 KB)
- IBM\_Limpeza\_NN\_SVM (manuela - v1, 5/2/17 4:07 PM - 8 KB)
- IBM\_MissingValues (manuela - v1, 5/4/17 12:12 PM - 13 KB)
- IBM\_NeuralNet\_DecisionTree (manuela - v1, 5/4/17 12:12 PM - 13 KB)

Operators

aprio

- Extensions (2)
  - Weka (2)
    - Modeling (2)
      - Associations (2)
        - W-PredictiveApriori
        - W-Apriori

No results were found.

Drag to move.

Process

Process

100%

Supermercado Franc s Apriori

Read CSV

Nominal to Text

Process Documents...

Select Attributes

Numerical to Binomi...

Store

W-Apriori (2)

Parameters

W-Apriori (2) (W-Apriori)

|   |                          |
|---|--------------------------|
| N | 20.0                     |
| T | 1.0                      |
| C | 0.2                      |
| D | 0.05                     |
| U | 1.0                      |
| M | 0.005                    |
| S | -1.0                     |
| I | <input type="checkbox"/> |
| R | <input type="checkbox"/> |
| V | <input type="checkbox"/> |
| A | <input type="checkbox"/> |
| c | 0.0                      |

## • SUPPORT

- Otimizar venda de produtos comprados pelo menos 5 vezes ao dia; Por semana:  $5*7$ :

✓ Support (m nimo) =  $5*7/7501 \sim 0.005$

//Local Repository/processes/aula05\_print\* - RapidMiner Studio Educational 7.5.001 @ ICA-080

File Edit Process View Connections Cloud Settings Extensions

Views: Design Results

Need help?

Repository

+ Add Data

- Aula03\_Full (manoela - v1, 5/11/17 11:02 AM - 31 KB)
- Aula03\_Full\_2 (manoela - v1, 5/11/17 5:05 PM - 31 KB)
- Aula03\_Full\_R\_TESTE (manoela - v1, 5/11/17 11:02 AM - 31 KB)
- Aula04 (manoela - v1, 5/23/17 7:01 PM - 55 KB)
- Aula04\_Print (manoela - v1, 5/25/17 2:33 PM - 42 KB)
- Aula05\_1 (manoela - v1, 5/31/17 10:59 AM - 13 KB)
- Aula05\_2 (manoela - v1, 5/30/17 5:03 PM - 9 KB)
- aula05\_print (manoela - v1, 5/31/17 12:58 PM - 1 KB)
- IBM\_AttributeSelection (manoela - v1, 5/3/17 10:05 AM - 10 KB)
- IBM\_AttributeSelection\_1 (manoela - v1, 5/4/17 12:12 PM - 10 KB)
- IBM\_AttributeSelection\_2 (manoela - v1, 5/4/17 12:12 PM - 10 KB)
- IBM\_IG\_WeightSelection (manoela - v1, 5/4/17 12:12 PM - 10 KB)
- IBM\_Limpeza (manoela - v1, 5/2/17 4:07 PM - 8 KB)
- IBM\_Limpeza\_NN\_SVM (manoela - v1, 5/2/17 4:07 PM - 8 KB)
- IBM\_MissingValues (manoela - v1, 5/4/17 12:12 PM - 10 KB)
- IBM\_NeuralNet\_DecisionTree (manoela - v1, 5/4/17 12:12 PM - 10 KB)

Operators

aprio

Extensions (2)

- Weka (2)
- Modeling (2)
- Association (2)

No results  
Drag to move.

Process

Process

100%

Supermercado Franc s Apriori

Read CSV

Nominal to Text

Process Documents...

Select Attributes

Numerical to Binomi...

Store

W-Apriori (2)

Parameters

W-Apriori (2) (W-Apriori)

|   |       |
|---|-------|
| N | 20.0  |
| T | 1.0   |
| C | 0.2   |
| D | 0.05  |
| U | 1.0   |
| M | 0.005 |
| S | -1.0  |
| I |       |
| R |       |
| V |       |
| A |       |
| c | 0.0   |

## • CONFIDENCE

- Baixa: regras que n o fazem sentido;
- Alta: regras  bvias;

✓ Comece com o valor default (0.8) e v  diminuindo (tentativa e erro).

- Obs: Um valor de 0.8 significa que todas as regras geradas devem estar corretas em 80% das transa  es.

Repository

Process

Parameters

W-Apriori (2) (W-Apriori)

Supermercado Francês Apriori

Read CSV

Nominal to Text

Process Documents...

Select Attributes

Numerical to Binomi...

Store

W-Apriori (2)

Parameters

| Parameter | Value                    |
|-----------|--------------------------|
| N         | 20.0                     |
| T         | 1.0                      |
| C         | 0.2                      |
| D         | 0.05                     |
| U         | 1.0                      |
| Min       | 0.005                    |
| S         | -1.0                     |
| I         | <input type="checkbox"/> |
| R         | <input type="checkbox"/> |
| V         | <input type="checkbox"/> |
| A         | <input type="checkbox"/> |
| c         | 0.0                      |

aprio

Extensions (2)

Weka (2)

Modeling (2)

Associations (2)

W-PredictiveApriori

W-Apriori

No results were found.

Drag to move.

Process

Process

100%

Views: Design Results

Need help?


- **LIFT**

- ✓ Ordenar pelo LIFT em ordem decrescente.

- Lift =  $\text{Confiança} / \text{Suporte(Consequente)}$  (medida de melhora na recomendação considerando conhecimento a priori)


Regra: Se Dexter então Breaking Bad

# ENTENDA MELHOR!



100 usuários da Netflix  
10 gostaram da série 'Breaking Bad'


Regra: Se Dexter então Breaking Bad



40 gostaram da série 'Dexter' (em verde);

Hipótese: É provável que quem viu 'Dexter' goste também de 'Breaking Bad';

7 pessoas que gostaram de 'Breaking Bad', também gostaram de 'Dexter';



### Melhora na previsão considerando o conhecimento a priori.

- Se a Netflix recomendasse 'Breaking Bad' para uma pessoa aleatoriamente, a probabilidade dessa pessoa gostar da série seria de 10%;
- Se a Netflix utilizar um conhecimento a priori (pessoas que gostaram de 'Dexter' também gostarão de 'Breaking Bad'), a probabilidade de uma pessoa gostar 'Breaking Bad' é de 17.5%;
- Lift: melhora de 75% utilizando o conhecimento apriori.

# O CONTRÁRIO

## Melhora na previsão considerando o conhecimento a priori.

- Se a Netflix recomendasse 'Dexter' para uma pessoa aleatoriamente, a probabilidade dessa pessoa gostar da série seria de 40%: Suporte = 0.4
- Se a Netflix utilizar um conhecimento a priori (pessoas que gostaram de 'Breaking Bad' também gostarão de 'Dexter'), a probabilidade de uma pessoa gostar 'Dexter' é de  $7/10 = 70\%$ : Confiança = 0.7
- Lift: melhora de  $(0.7/0.4) = 1.75$ , ou seja, 75% de melhora utilizando o conhecimento apriori.

# LIFT

$A \rightarrow B$

Suporte (B)

$$\text{Confiança } (A \rightarrow B) = \frac{\text{Suporte}(A \cap B)}{\text{Suporte}(A)}$$

$$\text{LIFT} = \frac{\text{Confiança } (A \rightarrow B)}{\text{Suporte}(B)} = \frac{\frac{\text{Suporte}(A \cap B)}{\text{Suporte}(A)}}{\text{Suporte}(B)} = \frac{\text{Suporte}(A \cap B)}{\text{Suporte}(A) * \text{Suporte}(B)}$$

$$\text{LIFT}(B \rightarrow A) = \frac{\text{Suporte}(B \cap A)}{\text{Suporte}(B) * \text{Suporte}(A)}$$

Independe da ordem:  $A \rightarrow B$  ou  $B \rightarrow A$

O que muda é o suporte da premissa e a confiança da regra!

# ESTUDO DE CASO

# ESTUDO DE CASO

## Transações de um Supermercado

Lista de transações (compras) em um mercado francês:

- Cada linha da base é uma transação;
- Cada transação tem de 1 a N itens;
- Existem 119 produtos diferentes no mercado;
- Base tem 7501 transações feitas no decorrer de 1 semana.



**Tente colocar  $T=0$  no operador 'Apriori' (ordenar por *confidence*) e veja o que acontece!**

**Dica: '*mineral water*', '*eggs*' e '*spaghetti*' são os 3 itens mais comprados no supermercado.**



Volte o parâmetro T do operador  
'Apriori' para  $T=1$   
(ordenar por *lift*)

Perceber associações e implementar estratégias de oferta desses produtos;

Perceber associações nada óbvias;

Automatizar sistema de recomendação;

Aumentar vendas;

Oferecer produtos condizentes com o perfil do cliente.

# SCRIPT Python

# FP-GROWTH

# ALGORITMO FP-GROWTH (FREQUENT PATTERN)

Um dos algoritmos mais populares para cálculo de termos frequentes.

Usa uma representação eficiente da base de dados na forma de uma estrutura em árvore - FP-tree.

Dois scans no BD: 1º para contar itens frequentes, 2º para construir a FP-tree.

Uma vez a FP-tree construída, o algoritmo usa uma abordagem recursiva *divide-and-conquer* para obter os conjuntos de itens frequentes.

# CONSTRUÇÃO DA ESTRUTURA FP-TREE

| TID | Itens      |
|-----|------------|
| 1   | {B,A}      |
| 2   | {D,C,B}    |
| 3   | {E,D, C,A} |
| 4   | {E,D,A}    |
| 5   | {B,A,C}    |
| 6   | {B,D,A,C}  |
| 7   | {B,C}      |
| 8   | {A,B,C}    |
| 9   | {D,B,A}    |
| 10  | {E,C,B}    |

| Item | Frequência | Prioridade |
|------|------------|------------|
| A    | 7          | 1          |
| B    | 8          | 2          |
| C    | 7          | 3          |
| D    | 4          | 4          |
| E    | 3          | 5          |


| TID | Itens      |
|-----|------------|
| 1   | {A,B}      |
| 2   | {B,C,D}    |
| 3   | {A,C,D, E} |
| 4   | {A,D,E}    |
| 5   | {A,B,C}    |
| 6   | {A,B,C,D}  |
| 7   | {B,C}      |
| 8   | {A,B,C}    |
| 9   | {A,B,D}    |
| 10  | {B,C,E}    |

Itens ordenados por prioridade


# CONSTRUÇÃO DA ESTRUTURA FP-TREE

| TID | Itens      |
|-----|------------|
| 1   | {A,B}      |
| 2   | {B,C,D}    |
| 3   | {A,C,D, E} |
| 4   | {A,D,E}    |
| 5   | {A,B,C}    |
| 6   | {A,B,C,D}  |
| 7   | {B,C}      |
| 8   | {A,B,C}    |
| 9   | {A,B,D}    |
| 10  | {B,C,E}    |

***Depois de ler TID=1:***




***Depois de ler TID=2:***



# CONSTRUÇÃO DA ESTRUTURA FP-TREE

| TID | Itens      |
|-----|------------|
| 1   | {A,B}      |
| 2   | {B,C,D}    |
| 3   | {A,C,D, E} |
| 4   | {A,D,E}    |
| 5   | {A,B,C}    |
| 6   | {A,B,C,D}  |
| 7   | {B,C}      |
| 8   | {A,B,C}    |
| 9   | {A,B,D}    |
| 10  | {B,C,E}    |

*Depois de ler TID=3:*




# CONSTRUÇÃO DA FP-TREE

| TID | Itens     |
|-----|-----------|
| 1   | {A,B}     |
| 2   | {B,C,D}   |
| 3   | {A,C,D,E} |
| 4   | {A,D,E}   |
| 5   | {A,B,C}   |
| 6   | {A,B,C,D} |
| 7   | {B,C}     |
| 8   | {A,B,C}   |
| 9   | {A,B,D}   |
| 10  | {B,C,E}   |

**Transaction  
Database**

**Header table**

| Item | Pointer |
|------|---------|
| A    | 7       |
| B    | 8       |
| C    | 7       |
| D    | 4       |
| E    | 3       |



**Apontadores (em vermelho) são usadas para facilitar a geração dos termos frequentes.**

# FP-GROWTH


Árvore construída.

Agora devemos definir os padrões frequentes.

Suponha suporte mínimo igual a 2.

# FP-GROWTH

| Item | Frequência | Prioridade |
|------|------------|------------|
| A    | 7          | 1          |
| B    | 8          | 2          |
| C    | 7          | 3          |
| D    | 4          | 4          |
| E    | 3          | 5          |




**Construir a conditional pattern base para E:**

***Primeiro a ser escolhido é E para seguir ordem inversa da frequência. Portanto, o próximo será D.***

# FP-GROWTH

## Conditional tree para E:



## Conditional Pattern base para E:

$P = \{(A,C,D:1),$   
 $(A,D:1),$  } Esquerda  
 $(B,C:1)\}$  Direita

## Conditional FP-Tree:


~~$\{(A:2, C:1, D:2),$~~  Suporte mínimo = 2  
 ~~$(B:1, C:1)\}$~~

## Frequent Patterns:

$\{(A, E:2), (D, E:2), (A, D, E:2)\}$

# FP-GROWTH


| Item | Frequência | Prioridade |
|------|------------|------------|
| A    | 7          | 1          |
| B    | 8          | 2          |
| C    | 7          | 3          |
| D    | 4          | 4          |
| E    | 3          | 5          |



**Construir a conditional pattern base para D:**

# FP-GROWTH

## Conditional tree para D:



○ mesmo é feito para todos os itens e todas as conditional trees em ordem decrescente de frequência.

## Conditional Pattern base para D:

$P = \{(A,B,C:1),$   
 $(A,B:1),$   
 $(A,C:1),$   
 $(A:1),$   
 $(B,C:1)\}$

Esquerda

Direita

## Conditional FP-Tree:

$\{(A:4, B:2, C:2), \text{~~(B:1, C:1)}~~\}$  Suporte mínimo = 2

## Frequent Patterns:

$\{(A, D:4), (B, D:2), (C, D:2), (A, B, D:2),$   
 $(A, C, D:2), (B, C, D:2), (A, B, C, D:2)\}$

# ESTUDO DE CASO

# ESTUDO DE CASO

## Transações de um Supermercado

Lista de transações (compras) em um mercado francês:

- Cada linha da base é uma transação;
- Cada transação tem de 1 a N itens;
- Existem 119 produtos diferentes no mercado;
- Base tem 7501 transações feitas no decorrer de 1 semana.



# PYTHON SCRIPTS

FP-Growth

ECLAT

# OBSERVAÇÃO

A saída do algoritmo Eclat não nos fornece regras, mas sim a lista dos itens mais frequentemente comprados juntos.