



Aprimorando a Técnica Small Loss Approach para Lidar com Amostras Ruidosas em Modelos Deep Learning

Vitor Bento de Sousa

Email: vitorbsousa@ica.ele.puc-rio.br


Sumário



1. Introdução
2. Função de Custo
3. Estado da Arte
4. Aprimorando a Técnica Small Loss Approach
5. Resultados
6. Conclusão

Introdução


Dataset Com Amostras Ruidosas



Introdução

Motivos:


- Uso de não especialistas no processo de anotação
- Fadiga
- Erro de programação
- Anotadores com conceitos diferentes para seleção das classes




Introdução

Consequência:

- Baixa Generalização do modelo



Função de Custo



Representação da função de custo. Nesse exemplo o modelo errou a classificação da imagem de cachorro com gato. Nesse caso a função de custo deve atribuir um erro alto, caso tivesse acertado a classe o erro seria zero.

Função de Custo

Em Deep Learning usualmente se utiliza a **Cross-Entropy (CE)** como **Função de Custo**, principalmente em problemas de classificação de imagens.

$$CE(p, q) = - \int_x p(x) \log(q(x)) dx$$

Onde p e q representam duas funções de densidade de probabilidade, sendo q a estimada pelo modelo e p a real oriunda dos dados disponíveis para treino

Função de Custo

$$CE(P_D, P_{model}) = - \int_X P_D(x) \log P_{model}(x) dx$$

Utilizar a CE como função de custo reduz a dissimilaridade entre a distribuição empírica dos dados e a distribuição aprendida pelo modelo

P_D : função densidade de probabilidade dos dados com amostras limpas
 P_{model} : função densidade de probabilidade aprendida pelo modelo


Consequências

Treinamento com dados ruidosos :

- Utilizar a **Cross-Entropy (CE)** como **Função de Custo** aumenta a similaridade entre P_D e P_{model}
- Em caso de amostras ruidosas P_{model} se aproxima da curva **incorreta** P_D'

Estado da Arte

Small Loss Approach (SLA)



Estado da Arte

Como identificar as amostras ruidosas?

Estado da Arte

Modelos de Deep Learning **primeiro** aprendem as amostras mais **simples** do Dataset



Amostras simples primeiro



Amostras complexas depois

Aprendizado




Estado da Arte

Modelos de Deep Learning **primeiro** aprendem as amostras mais **simples** do Dataset



Amostras complexas depois




Amostras ruidosas são as mais complexas

Aprendizado


Estado da Arte

É possível **identificar** as amostras ruidosas com **o valor do Erro** da Função de Custo



Estado da Arte


Small Loss Approach (SLA)




Aprimorando a Técnica Small Loss Approach

Como aprimorar a técnica Small Loss Approach?

Aprimorando a Técnica Small Loss Approach



Aprimorando a Técnica Small Loss Approach



Aprimorando a Técnica Small Loss Approach

Require: Rede $w_f(\theta_1)$ e Rede $w_g(\theta_2)$, learning rate η , fixo
 τ , época T_k , T_{max} , Dataset Ruidoso $D = (x_i, y_i)_{i=1}^z$,
 $R(t)$, iteração N_{max} :

- 1:
- 1: **for** $T = 1, 2, \dots, T_{max}$ **do**
- 2: Embaralhe o conjunto de dados D
- 3:
- 3: **for** $N = 1, 2, \dots, N_{max}$ **do**
- 4: Obtenha o mini-batch D_n de D
- 5: Obtenha as amostras limpas $\bar{D}_f$
utilizando o procedimento aprimorado
da SLA sobre D_n com a rede $w_f(\theta_1)$
- 6: Obtenha as amostras limpas $\bar{D}_g$
utilizando o procedimento aprimorado
da SLA sobre D_n com a rede $w_g(\theta_2)$
- 7: Atualize: $w_f(\theta_1) = w_f(\theta_1) - \eta \nabla CE(\theta_1, \bar{D}_g)$
- 8: Atualize: $w_g(\theta_2) = w_g(\theta_2) - \eta \nabla CE(\theta_2, \bar{D}_f)$
- 9: Atualize: $R(t) = \min[\frac{\tau t}{T_k}, \tau]$
- 10:

Experimental

Dataset Cifar-10 Com 45% De Ruído Pairflip Inserido Artificialmente


Métrica Label Precision

Test Accuracy

Comparação dos Modelos:

- Co-teaching Com a Small Loss Approach
- Co-teaching Com o Aprimoramento da Técnica Small Loss Approach

Resultados



Modelo	Época	Label Precision
Co-teaching	10	74%
Knn Co-teaching	10	76%
Co-teaching	150	72%
Knn Co-teaching	150	72%

Conclusão

Apresentou-se uma forma de aprimorar técnica Small Loss Approach utilizada para identificar amostras ruidosas com o uso do K-Nearest Neighbors Classifier

O primeiro experimento realizado sobre o dataset CIFAR-10 apontou uma melhoria de 1.2% no Test Accuracy e de 2% no Label Precision.

Próximos Passos:

- Ampliar a validação do Processo
- Os modelos serão utilizadas em uma demanda real de importância ambiental para classificação de algas calcárias.

Conclusão

Obrigado!