

REGRESSÃO

MANOELA KOHLER



Prof.manoela@ica.ele.puc-rio.br



www.linkedin.com/in/manoelakohler

TÓPICOS

R

Análise exploratória

Pré-processamento

- Balanceamento
- Outliers
- Missing values
- Normalização
- Seleção de atributos (Filtros, Wrappers, PCA)

Associação:

- Apriori
- FP-Growth
- Eclat

Classificação:

- Regressão logística
- Support Vector Machine (SVM)
- Árvores de Decisão
- Random Forest
- ~~Redes Neurais~~
- K nearest neighbors

Regressão

- Regressão linear simples
- Regressão linear múltipla
- Regressão não linear simples
- Regressão não linear múltipla

Agrupamento

- Particionamento (K-means, K-medoids)
- Hierárquico (DIANA, AGNES)
- Densidade (DBSCAN)

Séries Temporais

- Naive
- Média Móvel
- Amortecimento exponencial
- Auto-regressivo integrados de média móvel
- Auto regressivo não linear

Recapitulação

AGRUPAMENTO (CLUSTERIZAÇÃO)


MÉTODOS DE CLUSTERIZAÇÃO

- **Particionamento:** Constrói várias partições e as avalia usando algum critério.
- **Hierárquico:** Cria uma decomposição hierárquica dos objetos usando algum critério.
- **Baseado em densidade:** Fundamenta-se em funções de conectividade e de densidade.

Machine Learning


Supervisionado

Classificação
Regressão
Previsão de séries temporais




Não Supervisionado

Agrupamento
Associação



Reforço

Aprendizado através da interação de agentes com um ambiente




SUPERVISIONADO

- Aproximador: função mapeia entradas e saída.


Classificação

Rótulo é categórico.



Regressão

Rótulo é contínuo.



Previsão de Séries


Rótulo é contínuo e dependente do tempo.



NÃO SUPERVISIONADO

Agrupamento

Descoberta de semelhanças e grupos entre registros.



Associação

Descoberta de relações entre variáveis.



REGRESSÃO

CORRELAÇÃO

Indica a força e a direção do relacionamento entre dois atributos;

Trata-se de uma medida da relação entre dois atributos, embora correlação não implique causalidade:

- Duas variáveis podem estar altamente correlacionadas e não existir relação de causa e efeito entre elas.

REGRESSÃO

Existe uma série de técnicas voltadas para a modelagem e a investigação de relações entre dois ou mais atributos.

Exemplo:

- Na análise de correlação linear, o objetivo é determinar o grau de relacionamento entre duas variáveis.
- Já na análise de regressão linear, o objetivo é determinar o modelo que expressa esta relação (equação de regressão), a qual é ajustada aos dados.

REGRESSÃO

Para que serve?

Podemos usar esse modelo para prever o valor de y para um dado valor de x (ou $\vec{x}$)

- Realizar previsões sobre o comportamento futuro de algum fenômeno da realidade.
- Neste caso extrapola-se para o futuro as relações de causa-efeito – já observadas no passado – entre as variáveis.

REGRESSÃO

A análise de regressão compreende quatro tipos básicos de modelos:

- Linear simples;
- Linear Múltipla;
- Não linear simples;
- Não linear múltipla.

Regressão Linear Simples

REGRESSÃO

Regressão
Linear Simples

$$y = b_0 + b_1 x_1$$

Variável dependente


Intercepto (constante)

Coeficiente

Variável independente


REGRESSÃO

Simple Linear Regression:



REGRESSÃO


Simple Linear Regression:



$$y = b_0 + b_1 * x$$

REGRESSÃO

Simple Linear Regression:




$$y = b_0 + b_1 * x$$



$$\text{Salary} = b_0 + b_1 * \text{Experience}$$

REGRESSÃO

Simple Linear Regression:




$$y = b_0 + b_1 * x$$



Salary $(b_0 + b_1 * \text{Experience})$

REGRESSÃO

Simple Linear Regression:




$$y = b_0 + b_1 * x$$

↓

$$\text{Salary} = b_0 + b_1 * \text{Experience}$$


RESÍDUOS

Simple Linear Regression:





RESÍDUOS

Simple Linear Regression:



RESÍDUOS

Simple Linear Regression:



Resíduos

$$\sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

$$\sum_{i=1}^n (e_i)^2$$

Minimizar

REGRESSÃO

Uma análise de regressão gera uma equação para descrever a relação entre um ou mais preditores e a variável resposta e para prever novas observações com um valor preditor com precisão maior que o acaso.

A regressão linear geralmente usa o método de estimativa de mínimos quadrados comum que deriva a equação minimizando a soma dos resíduos quadrados.

REGRESSÃO LINEAR SIMPLES

A regressão fornece a linha que "melhor" ajusta os dados. Essa linha pode ser usada para:

- Examinar como a variável de resposta muda quando o preditor muda.
- Predizer o valor de uma variável de resposta para qualquer variável preditora.

Regressão Linear Múltipla

REGRESSÃO LINEAR MÚLTIPLA

A regressão linear múltipla examina as relações lineares entre uma resposta contínua e dois ou mais preditores.

REGRESSÃO

Regressão
Linear Simples

$$y = b_0 + b_1x_1$$

Regressão
Linear Múltipla

Variável dependente

Variáveis independentes

$$y = b_0 + b_1x_1 + b_2x_2 + \cdots + b_nx_n$$

Métricas

MÉTRICAS

$$\text{MAPE} = \frac{\sum_{t=1}^n \frac{\text{real} - \text{previsto}}{\text{real}}}{n}$$

$$\text{RMSE} = \sqrt{\frac{\sum_{t=1}^n (\text{real} - \text{previsto})^2}{n}}$$

$$R^2 = 1 - \frac{SSr}{SS_{tot}}$$

$$R^2_{ajustado} = 1 - (1 - R^2) \frac{n-1}{n-p-1}$$

O MAPE tenta capturar a importância do erro relativo, fornecendo um valor percentual, enquanto o RMSE fornece o erro na dimensão da variável e mede a magnitude média do erro.

R^2 representa a porcentagem de variação na resposta que é explicada pelo modelo. Quanto mais alto o valor de R^2 (ajustado) melhor o modelo ajusta seus dados.



n = número de amostras

p = número de regressores (ou variáveis independentes ou atributos)

R Squared

R^2

Simple Linear Regression:



Resíduos


$$\sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

$$\sum_{i=1}^n (e_i)^2$$

Minimizar

R^2


Simple Linear Regression:



$$\sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

R²

Simple Linear Regression:




Soma dos quadrados
dos resíduos

$$SS_{res} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

R²

Simple Linear Regression:



Soma dos quadrados
dos resíduos


$$SS_{res} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

$$SS_{tot} = \sum_{i=1}^n (Y_i - Y_{avg})^2$$

Soma dos quadrados
total

R²

Simple Linear Regression:



$$SS_{res} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

$$SS_{tot} = \sum_{i=1}^n (Y_i - Y_{avg})^2$$

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

O normal é que esta métrica esteja entre 0 e 1.

R² AJUSTADO

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

R^2 - Quão bom é o modelo
(quanto maior, melhor)

Problema:

$$y = b_0 + b_1x_1 + b_2x_2 \leftarrow +b_3x_3$$

$SS_{res} \Rightarrow \text{Min}$

x_3 pode ser insignificante
 R^2 pode aumentar

R² AJUSTADO

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

$$R^2_{aj} = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

n = número de dados

p = número de regressores

ESTUDO DE CASO

Startups



50 Startups:

- 4 variáveis independentes (explicativas):
 - Gastos com P&D;
 - Gastos administrativos;
 - Gastos com marketing;
 - Estado.
- Variável dependente (resposta):
 - Lucro

Regressão com objetivo de criar um modelo para investidores.

DEVEMOS SABER

DUMMY VARIABLES

Profit	R&D Spend	Admin	Marketing	State
192,261.83	165,349.20	136,897.80	471,784.10	New York
191,792.06	162,597.70	151,377.59	443,898.53	California
191,050.39	153,441.51	101,145.55	407,934.54	California
182,901.99	144,372.41	118,671.85	383,199.62	New York
166,187.94	142,107.34	91,391.77	366,168.42	California

DUMMY VARIABLES

Profit	R&D Spend	Admin	Marketing	State
192,261.83	165,349.20	136,897.80	471,784.10	New York
191,792.06	162,597.70	151,377.59	443,898.53	California
191,050.39	153,441.51	101,145.55	407,934.54	California
182,901.99	144,372.41	118,671.85	383,199.62	New York
166,187.94	142,107.34	91,391.77	366,168.42	California

$y =$

DUMMY VARIABLES

Profit	R&D Spend	Admin	Marketing	State
192,261.83	165,349.20	136,897.80	471,784.10	New York
191,792.06	162,597.70	151,377.59	443,898.53	California
191,050.39	153,441.51	101,145.55	407,934.54	California
182,901.99	144,372.41	118,671.85	383,199.62	New York
166,187.94	142,107.34	91,391.77	366,168.42	California

$$y = b_0 +$$

DUMMY VARIABLES

Profit	R&D Spend	Admin	Marketing	State
192,261.83	165,349.20	136,897.80	471,784.10	New York
191,792.06	162,597.70	151,377.59	443,898.53	California
191,050.39	153,441.51	101,145.55	407,934.54	California
182,901.99	144,372.41	118,671.85	383,199.62	New York
166,187.94	142,107.34	91,391.77	366,168.42	California

$$y = b_0 + b_1 * x_1$$

DUMMY VARIABLES

Profit	R&D Spend	Admin	Marketing	State
192,261.83	165,349.20	136,897.80	471,784.10	New York
191,792.06	162,597.70	151,377.59	443,898.53	California
191,050.39	153,441.51	101,145.55	407,934.54	California
182,901.99	144,372.41	118,671.85	383,199.62	New York
166,187.94	142,107.34	91,391.77	366,168.42	California

$$y = b_0 + b_1 * x_1 + b_2 * x_2$$

DUMMY VARIABLES

Profit	R&D Spend	Admin	Marketing	State
192,261.83	165,349.20	136,897.80	471,784.10	New York
191,792.06	162,597.70	151,377.59	443,898.53	California
191,050.39	153,441.51	101,145.55	407,934.54	California
182,901.99	144,372.41	118,671.85	383,199.62	New York
166,187.94	142,107.34	91,391.77	366,168.42	California

$$y = b_0 + b_1 * x_1 + b_2 * x_2 + b_3 * x_3$$

DUMMY VARIABLES

Profit	R&D Spend	Admin	Marketing	State
192,261.83	165,349.20	136,897.80	471,784.10	New York
191,792.06	162,597.70	151,377.59	443,898.53	California
191,050.39	153,441.51	101,145.55	407,934.54	California
182,901.99	144,372.41	118,671.85	383,199.62	New York
166,187.94	142,107.34	91,391.77	366,168.42	California

$$y = b_0 + b_1 * x_1 + b_2 * x_2 + b_3 * x_3 + ???$$

DUMMY VARIABLES

Profit	R&D Spend	Admin	Marketing	State	New York	California
192,261.83	165,349.20	136,897.80	471,784.10	New York		
191,792.06	162,597.70	151,377.59	443,898.53	California		
191,050.39	153,441.51	101,145.55	407,934.54	California		
182,901.99	144,372.41	118,671.85	383,199.62	New York		
166,187.94	142,107.34	91,391.77	366,168.42	California		

$$y = b_0 + b_1 * x_1 + b_2 * x_2 + b_3 * x_3 + ???$$

DUMMY VARIABLES

Profit	R&D Spend	Admin	Marketing	State	New York	California
192,261.83	165,349.20	136,897.80	471,784.10	New York	1	
191,792.06	162,597.70	151,377.59	443,898.53	California	0	
191,050.39	153,441.51	101,145.55	407,934.54	California	0	
182,901.99	144,372.41	118,671.85	383,199.62	New York	1	
166,187.94	142,107.34	91,391.77	366,168.42	California	0	

$$y = b_0 + b_1 * x_1 + b_2 * x_2 + b_3 * x_3 + ???$$

DUMMY VARIABLES

Profit	R&D Spend	Admin	Marketing	State	New York	California
192,261.83	165,349.20	136,897.80	471,784.10	New York	1	0
191,792.06	162,597.70	151,377.59	443,898.53	California	0	1
191,050.39	153,441.51	101,145.55	407,934.54	California	0	1
182,901.99	144,372.41	118,671.85	383,199.62	New York	1	0
166,187.94	142,107.34	91,391.77	366,168.42	California	0	1

$$y = b_0 + b_1 * x_1 + b_2 * x_2 + b_3 * x_3 + ???$$

DUMMY VARIABLES

					Dummy Variables	
Profit	R&D Spend	Admin	Marketing	State	New York	California
192,261.83	165,349.20	136,897.80	471,784.10	New York	1	0
191,792.06	162,597.70	151,377.59	443,898.53	California	0	1
191,050.39	153,441.51	101,145.55	407,934.54	California	0	1
182,901.99	144,372.41	118,671.85	383,199.62	New York	1	0
166,187.94	142,107.34	91,391.77	366,168.42	California	0	1


$$y = b_0 + b_1 * x_1 + b_2 * x_2 + b_3 * x_3 + b_4 * D_1$$

DUMMY VARIABLES

					Dummy Variables	
Profit	R&D Spend	Admin	Marketing	State	New York	California
192,261.83	165,349.20	136,897.80	471,784.10	New York	1	0
191,792.06	162,597.70	151,377.59	443,898.53	California	0	1
191,050.39	153,441.51	101,145.55	407,934.54	California	0	1
182,901.99	144,372.41	118,671.85	383,199.62	New York	1	0
166,187.94	142,107.34	91,391.77	366,168.42	California	0	1

$$y = b_0 + b_1 * x_1 + b_2 * x_2 + b_3 * x_3$$

$$+ b_4 * D_1$$



DUMMY VARIABLE TRAP

Profit	R&D Spend	Admin	Marketing	State	Dummy Variables	
					New York	California
					1	0
					0	1
					0	1
					1	0
192,261.83	165,349.20	136,897.80	471,784.10	New York	1	0
191,792.06	162,597.70	151,377.59	443,898.53	California	0	1
191,050.39	153,441.51	101,145.55	407,934.54	California	0	1
182,901.99	144,372.41	118,671.85	383,199.62	New York	1	0
166,187.94	142,107.34	91,391.77	366,168.42	California	0	1

$$y = b_0 + b_1 * x_1 + b_2 * x_2 + b_3 * x_3 + b_4 * D_1 + \underline{b_5 * D_2}$$

DUMMY VARIABLE TRAP

Profit	R&D Spend	Admin	Marketing	State
192,261.83	165,3	$D_2 = 1 - D_1$		
191,792.06	162,5			
191,050.39	153,4			
182,901.99	144,3			
166,187.94	142,107.54			

Multicolinearidade

Dummy Variables

New York	California
1	0
0	1
0	1
1	0
0	1

$$y = b_0 + b_1 * x_1 + b_2 * x_2 + b_3 * x_3 + b_4 * D_1 + \underline{b_5 * D_2}$$

O modelo pode não funcionar de forma apropriada

Call:

```
lm(formula = Profit ~ ., data = training_set)
```

Residuals:

Min	1Q	Median	3Q	Max
-33128	-4865	5	6098	18065

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	4.965e+04	7.637e+03	6.501	1.94e-07	***
R.D.Spend	7.986e-01	5.604e-02	14.251	6.70e-16	***
Administration	-2.942e-02	5.828e-02	-0.505	0.617	
Marketing.Spend	3.268e-02	2.127e-02	1.537	0.134	
State2	1.213e+02	3.751e+03	0.032	0.974	
State3	2.376e+02	4.127e+03	0.058	0.954	

Coeficiente: o modelo estima um aumento esperado de 0.79 no lucro para cada 1 unidade (no caso, 1 dólar) de aumento de gasto com pesquisa e desenvolvimento (quando as outras variáveis são mantidas constantes).

```
Call:
lm(formula = Profit ~ ., data = training_set)
```

Residuals:

Min	1Q	Median	3Q	Max
-33128	-4865	5	6098	18065

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	4.965e+04	7.637e+03	6.501	1.94e-07	***
R.D.Spend	7.986e-01	5.604e-02	14.251	6.70e-16	***
Administration	-2.942e-02	5.828e-02	-0.505	0.617	
Marketing.Spend	3.268e-02	2.127e-02	1.537	0.134	
State2	1.213e+02	3.751e+03	0.032	0.974	
State3	2.376e+02	4.127e+03	0.058	0.954	

Desvio padrão: quão preciso foi a estimação do coeficiente da variável em questão. Quanto menor, mais precisa é a estimativa.


```
Call:
lm(formula = Profit ~ ., data = training_set)
```

Residuals:

Min	1Q	Median	3Q	Max
-33128	-4865	5	6098	18065

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	4.965e+04	7.637e+03	6.501	1.94e-07	***
R.D.Spend	7.986e-01	5.604e-02	14.251	6.70e-16	***
Administration	-2.942e-02	5.828e-02	-0.505	0.617	
Marketing.Spend	3.268e-02	2.127e-02	1.537	0.134	
State2	1.213e+02	3.751e+03	0.032	0.974	
State3	2.376e+02	4.127e+03	0.058	0.954	

T value: Estimate/Standard Error
Quanto desvios padrões do zero o coeficiente estimado está.

Call:

```
lm(formula = Profit ~ ., data = training_set)
```

Residuals:

Min	1Q	Median	3Q	Max
-33128	-4865	5	6098	18065

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	4.965e+04	7.637e+03	6.501	1.94e-07	***
R.D.Spend	7.986e-01	5.604e-02	14.251	6.70e-16	***
Administration	-2.942e-02	5.828e-02	-0.505	0.617	
Marketing.Spend	3.268e-02	2.127e-02	1.537	0.134	
State2	1.213e+02	3.751e+03	0.032	0.974	
State3	2.376e+02	4.127e+03	0.058	0.954	

P-value: testa a hipótese nula onde o coeficiente é igual a zero (sem efeito). Um $p\text{-value} < 0.05$ indica que você pode rejeitar a hipótese nula. Em outras palavras, um preditor que tem um p-value pequeno é provavelmente uma boa adição ao seu modelo (estatisticamente significativo).

```
Call:
lm(formula = Profit ~ ., data = training_set)
```

Residuals:

Min	1Q	Median	3Q	Max
-33128	-4865	5	6098	18065

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	4.965e+04	7.637e+03	6.501	1.94e-07	***
R.D.Spend	7.986e-01	5.604e-02	14.251	6.70e-16	***
Administration	-2.942e-02	5.828e-02	-0.505	0.617	
Marketing.Spend	3.268e-02	2.127e-02	1.537	0.134	
State2	1.213e+02	3.751e+03	0.032	0.974	
State3	2.376e+02	4.127e+03	0.058	0.954	

signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

SCRIPT

```
Call:
lm(formula = Profit ~ ., data = training_set)

Residuals:
    Min       1Q   Median       3Q      Max
-33128  -4865        5    6098  18065

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.965e+04  7.637e+03   6.501 1.94e-07 ***
R.D.Spend    7.986e-01  5.604e-02  14.251 6.70e-16 ***
Administration -2.942e-02  5.828e-02  -0.505   0.617
Marketing.Spend 3.268e-02  2.127e-02   1.537   0.134
State2       1.213e+02  3.751e+03   0.032   0.974
State3       2.376e+02  4.127e+03   0.058   0.954
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9908 on 34 degrees of freedom
Multiple R-squared:  0.9499,    Adjusted R-squared:  0.9425
F-statistic: 129 on 5 and 34 DF,  p-value: < 2.2e-16
```

```
Call:
lm(formula = Profit ~ ., data = training_set)

Residuals:
    Min       1Q   Median       3Q      Max
-33294  -4763    -354    6351  17693

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.638e+04  3.019e+03  15.364 <2e-16 ***
R.D.Spend    7.879e-01  4.916e-02  16.026 <2e-16 ***
Marketing.Spend 3.538e-02  1.905e-02   1.857   0.0713 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9533 on 37 degrees of freedom
Multiple R-squared:  0.9495,    Adjusted R-squared:  0.9468
F-statistic: 348.1 on 2 and 37 DF,  p-value: < 2.2e-16
```

```
Call:
lm(formula = Profit ~ ., data = training_set)

Residuals:
    Min       1Q   Median       3Q      Max
-33117  -4858       -36    6020  17957

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.970e+04  7.120e+03   6.980 3.48e-08 ***
R.D.Spend    7.983e-01  5.356e-02  14.905 < 2e-16 ***
Administration -2.895e-02  5.603e-02  -0.517   0.609
Marketing.Spend 3.283e-02  1.987e-02   1.652   0.107
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9629 on 36 degrees of freedom
Multiple R-squared:  0.9499,    Adjusted R-squared:  0.9457
F-statistic: 227.6 on 3 and 36 DF,  p-value: < 2.2e-16
```

```
Call:
lm(formula = Profit ~ ., data = training_set)

Residuals:
    Min       1Q   Median       3Q      Max
-34334  -4894    -340    6752  17147

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.902e+04  2.748e+03  17.84 <2e-16 ***
R.D.Spend    8.563e-01  3.357e-02  25.51 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9836 on 38 degrees of freedom
Multiple R-squared:  0.9448,    Adjusted R-squared:  0.9434
F-statistic: 650.8 on 1 and 38 DF,  p-value: < 2.2e-16
```

R SCRIPT

```
Call:
lm(formula = Profit ~ ., data = training_set)

Residuals:
    Min       1Q   Median       3Q      Max
-33128  -4865        5    6098  18065

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.965e+04  7.637e+03   6.501 1.94e-07 ***
R.D.Spend    7.986e-01  5.604e-02  14.251 6.70e-16 ***
Administration -2.942e-02  5.828e-02  -0.505  0.617
Marketing.Spend 3.268e-02  2.127e-02   1.537  0.134
State2        1.213e+02  3.751e+03   0.032  0.974
State3        2.376e+02  4.127e+03   0.058  0.954
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9908 on 34 degrees of freedom
Multiple R-squared:  0.9499,    Adjusted R-squared:  0.9425
```

```
Call:
lm(formula = Profit ~ ., data = training_set)

Residuals:
    Min       1Q   Median       3Q      Max
-33294  -4763    -354    6351  17693

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.638e+04  3.019e+03  15.364 <2e-16 ***
R.D.Spend    7.879e-01  4.916e-02  16.026 <2e-16 ***
Marketing.Spend 3.538e-02  1.905e-02   1.857  0.0713 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9836 on 34 degrees of freedom
Multiple R-squared:  0.9495,    Adjusted R-squared:  0.9468
```

```
Call:
lm(formula = Profit ~ ., data = training_set)

Residuals:
    Min       1Q   Median       3Q      Max
-33117  -4858       -36    6020  17957

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.970e+04  7.120e+03   6.980 3.48e-08 ***
R.D.Spend    7.983e-01  5.356e-02  14.905 < 2e-16 ***
Administration -2.895e-02  5.603e-02  -0.517  0.609
Marketing.Spend 3.283e-02  1.987e-02   1.652  0.107
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9925 on 34 degrees of freedom
Multiple R-squared:  0.9499,    Adjusted R-squared:  0.9457
```

```
Call:
lm(formula = Profit ~ ., data = training_set)

Residuals:
    Min       1Q   Median       3Q      Max
-34334  -4894    -340    6752  17147

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.902e+04  2.748e+03  17.84  <2e-16 ***
R.D.Spend    8.563e-01  3.357e-02  25.51  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9836 on 34 degrees of freedom
Multiple R-squared:  0.9448,    Adjusted R-squared:  0.9434
```

R SCRIPT

```
Call:
lm(formula = Profit ~ ., data = training_set)

Residuals:
    Min       1Q   Median       3Q      Max
-33128  -4865        5    6098  18065

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.965e+04  7.637e+03   6.501 1.94e-07 ***
R.D.Spend    7.986e-01  5.604e-02  14.251 6.70e-16 ***
Administration -2.942e-02  5.828e-02  -0.505  0.617
Marketing.Spend 3.268e-02  2.127e-02   1.537  0.134
State2        1.213e+02  3.751e+03   0.032  0.974
State3        2.376e+02  4.127e+03   0.058  0.954
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9908 on 34 degrees of freedom
Multiple R-squared:  0.9499,    Adjusted R-squared:  0.9425
F-statistic: 129 on 5 and 34 DF,  p-value: < 2.2e-16
```

```
Call:
lm(formula = Profit ~ ., data = training_set)

Residuals:
    Min       1Q   Median       3Q      Max
-33294  -4763    -354    6351  17693

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.638e+04  3.019e+03  15.364 <2e-16 ***
R.D.Spend    7.879e-01  4.916e-02  16.026 <2e-16 ***
Marketing.Spend 3.538e-02  1.905e-02   1.857  0.0713 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9533 on 37 degrees of freedom
Multiple R-squared:  0.9495,    Adjusted R-squared:  0.9468
F-statistic: 348.1 on 2 and 37 DF,  p-value: < 2.2e-16
```

```
Call:
lm(formula = Profit ~ ., data = training_set)

Residuals:
    Min       1Q   Median       3Q      Max
-33117  -4858     -36    6020  17957

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.970e+04  7.120e+03   6.980 3.48e-08 ***
R.D.Spend    7.983e-01  5.356e-02  14.905 < 2e-16 ***
Administration -2.895e-02  5.603e-02  -0.517  0.609
Marketing.Spend 3.283e-02  1.987e-02   1.652  0.107
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9629 on 36 degrees of freedom
Multiple R-squared:  0.9499,    Adjusted R-squared:  0.9457
F-statistic: 227.6 on 3 and 36 DF,  p-value: < 2.2e-16
```

```
Call:
lm(formula = Profit ~ ., data = training_set)

Residuals:
    Min       1Q   Median       3Q      Max
-34334  -4894    -340    6752  17147

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.902e+04  2.748e+03  17.84 <2e-16 ***
R.D.Spend    8.563e-01  3.357e-02  25.51 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9836 on 38 degrees of freedom
Multiple R-squared:  0.9448,    Adjusted R-squared:  0.9434
F-statistic: 650.8 on 1 and 38 DF,  p-value: < 2.2e-16
```




Árvores de Regressão

ÁRVORES DE REGRESSÃO



CART

ÁRVORES DE REGRESSÃO



Breiman, Leo, et al. Classification and regression trees. CRC press, 1984


ÁRVORES DE REGRESSÃO




Minimiza soma do erro quadrático pros lados direito e esquerdo

ÁRVORES DE REGRESSÃO


Splits escolhidos a partir de valores da base de dados e de forma a minimizar a soma dos erros quadráticos!




ÁRVORES DE REGRESSÃO




ÁRVORES DE REGRESSÃO




ÁRVORES DE REGRESSÃO




ÁRVORES DE REGRESSÃO




ÁRVORES DE REGRESSÃO




ÁRVORES DE REGRESSÃO




ÁRVORES DE REGRESSÃO




ÁRVORES DE REGRESSÃO



ÁRVORES DE REGRESSÃO




ÁRVORES DE REGRESSÃO



Random Forest

RANDOM FOREST



RANDOM FOREST

PASSO 1: Escolhe o número de árvores que se deseja construir e o espaço de atributos S e repete os passos 2 e 3 para cada uma das árvores.



PASSO 2: Escolhe aleatoriamente K dados e S atributos do conjunto de treinamento.




PASSO 3: Constrói a árvore de decisão associada àqueles K dados.




PASSO 4: Para cada dado novo, faça com que cada árvore da sua floresta infira um valor da variável resposta (dependente). A resposta do comitê será, por exemplo, a média aritmética da inferência de todas as árvores.

K Nearest Neighbors


KNN - CLASSIFICAÇÃO




KNN - CLASSIFICAÇÃO



KNN PARA REGRESSÃO




KNN PARA REGRESSÃO




KNN PARA REGRESSÃO

- **2NN para Regressão:** O Faturamento Esperado é a Média Aritmética dos 2 vizinhos mais próximos!



KNN PARA REGRESSÃO

- **3NN para Regressão:** O Faturamento Esperado é a Média Aritmética dos **3** vizinhos mais próximos!



ESTUDO DE CASO

Aluguel de Bicicletas (2011-2012)

<https://www.capitalbikeshare.com/>



- **9 variáveis independentes:**

- Estação do ano (1:primavera, 2:verão, 3:outono, 4:inverno);
- Feriado;
- Dia de semana;
- Dia de trabalho;
- Tempo (1:limpo, 2:nublado, 3:neve / chuva);
- Temperatura;
- Sensação térmica;
- Humidade;
- Velocidade do vento.

Variável resposta: horas de uso de bike.

Para Praticar!

ESTUDO DE CASO

Startups



50 Startups:

- 4 variáveis independentes (explicativas):
 - Gastos com P&D;
 - Gastos administrativos;
 - Gastos com marketing;
 - Estado.
- Variável dependente (resposta):
 - Lucro

Regressão com objetivo de criar um modelo para investidores.