

PREVISÃO DE SÉRIES TEMPORAIS

TÓPICOS

R

Análise exploratória

Pré-processamento

- Balanceamento
- Outliers
- Missing values
- Normalização
- Seleção de atributos (Filtros, Wrappers, PCA)

Associação:

- Apriori
- FP-Growth
- Eclat

Classificação:

- Regressão logística
- Support Vector Machine (SVM)
- Árvores de Decisão
- Random Forest
- ~~Redes Neurais~~
- K nearest neighbors

Regressão

- Regressão linear simples
- Regressão linear múltipla
- Regressão não linear simples
- Regressão não linear múltipla

Agrupamento

- Particionamento (K-means, K-medoids)
- Hierárquico (DIANA, AGNES)
- Densidade (DBSCAN)

Séries Temporais

- Naive
- Média Móvel
- Amortecimento exponencial
- Auto-regressivo integrados de média móvel
- Auto regressivo não linear

Recapitulação

CORRELAÇÃO

Indica a força e a direção do relacionamento entre dois atributos;

Trata-se de uma medida da relação entre dois atributos, embora correlação não implique causalidade:

- Duas variáveis podem estar altamente correlacionadas e não existir relação de causa e efeito entre elas.

REGRESSÃO

Existe uma série de técnicas voltadas para a modelagem e a investigação de relações entre dois ou mais atributos.

Exemplo:

- Na análise de correlação linear, o objetivo é determinar o grau de relacionamento entre duas variáveis.
- Já na análise de regressão linear, o objetivo é determinar o modelo que expressa esta relação (equação de regressão), a qual é ajustada aos dados.

REGRESSÃO

Regressão
Linear Simples

$$y = b_0 + b_1x_1$$

Regressão
Linear Múltipla

Variável dependente

Variáveis independentes

$$y = b_0 + b_1x_1 + b_2x_2 + \cdots + b_nx_n$$

MÉTRICAS

$$\text{MAPE} = \frac{\sum_{t=1}^n \frac{\text{real} - \text{previsto}}{\text{real}}}{n}$$

$$\text{RMSE} = \sqrt{\frac{\sum_{t=1}^n (\text{real} - \text{previsto})^2}{n}}$$

$$R^2 = 1 - \frac{SSr}{SS_{tot}}$$

$$R^2_{ajustado} = 1 - (1 - R^2) \frac{n-1}{n-p-1}$$


O MAPE tenta capturar a importância do erro relativo, fornecendo um valor percentual, enquanto o RMSE fornece o erro na dimensão da variável e mede a magnitude média do erro.

R^2 representa a porcentagem de variação na resposta que é explicada pelo modelo. Quanto mais alto o valor de R^2 (ajustado) melhor o modelo ajusta seus dados.

n = número de amostras

p = número de regressores (ou variáveis independentes ou atributos)

ÁRVORES DE REGRESSÃO



Breiman, Leo, et al. Classification and regression trees. CRC press, 1984

RANDOM FOREST

PASSO 1: Escolhe o número de árvores que se deseja construir e repete os passos 2 e 3 para cada uma das árvores.



PASSO 2: Escolhe aleatoriamente K dados e S atributos do conjunto de treinamento.




PASSO 3: Constrói a árvore de decisão associada àqueles K dados.



PASSO 4: Para cada dado novo, faça com que cada árvore da sua floresta infira um valor da variável resposta (dependente). A resposta do comitê será, por exemplo, a média aritmética da inferência de todas as árvores.

KNN PARA REGRESSÃO



Previsão de Séries Temporais

SÉRIES TEMPORAIS

Uma série temporal é um conjunto de observações ordenadas no tempo, não necessariamente igualmente espaçadas, que apresentam dependência serial, isto é, dependência entre instantes de tempo.




PREVISÃO DE SÉRIES TEMPORAIS

- Tipos possíveis de processamento:
- **Predição:** futuros valores de $x(t)$
- **Classificação:** uma série de uma ou algumas classes:
 - Preço vai subir
 - Preço vai cair
 - Sem mudanças
- **Transformação:** de uma série temporal em outra série temporal:
 - Preço do óleo → Consumo de gasolina nos postos

Cotação EURUSD


A TENDÊNCIA

Indica o seu comportamento “de longo prazo”, isto é, se ela cresce, decresce ou permanece estável, e qual a velocidade destas mudanças.




OS CICLOS

São caracterizados pelas **oscilações de subida** e de **queda** nas séries, de forma **não periódica**, ao longo da componente de tendência.




A SAZONALIDADE

Corresponde às **oscilações de subida e de queda** que sempre ocorrem em um determinado período do ano, do mês, da semana ou do dia.



SAZONALIDADE X CICLOS

A diferença essencial entre as componentes **sazonal** e **cíclica** é que a **primeira** possui **movimentos facilmente previsíveis**, ocorrendo em **intervalos regulares de tempo (periódico)**, enquanto que movimentos cíclicos tendem a ser irregulares.



Grande seca seguida de um ano com grande quantidade de chuva.

MODELOS DE PREVISÃO

- Naive
- Modelo de média móvel (MA)
- Modelo de Amortecimento Exponencial
- Modelo Auto-regressivo integrados de média móvel (ARIMA)
- Modelo Auto-regressivo Não Linear

NAIVE (INGÊNUO)

A previsão do valor da série no instante $T+1$ é apenas dado pela última observação da série em T .

Uma aplicação clássica é a previsão do preço de uma ação.

MÉDIAS MÓVEIS

A previsão é a média das últimas n observações.

Um dos problemas é a definição do tamanho da janela:

- Quanto maior o valor de n , mais “suave” é a previsão;
- Se n é pequeno, a previsão tende a oscilar muito.

Característica importante: todas as observações têm o mesmo peso.

Mas na prática, as observações mais recentes tendem a ser mais relevantes.

○ que nos leva aos modelos de amortecimento exponencial.

AMORTECIMENTO EXPONENCIAL

A ideia geral é parecida com método de médias móveis, mas os pesos das observações decrescem à medida que as observações estão mais longe.

A taxa de decréscimo dos pesos é determinada por uma ou mais constantes de amortecimento. A maior dificuldade é a escolha das constantes de amortecimento.

ARMA, ARIMA E SARIMA

ARMA: processos mistos AR e MA (séries estacionárias).

Modelos mais sofisticados:

Incluem modelos não estacionários (ARIMA) e sazonais (SARIMA);

MODELOS AUTO-REGRESSIVOS NÃO LINEARES

Modelos não lineares são mais poderosos, mas precisam de mais dados de treinamento e não são tão bem comportados quanto os modelos lineares.

Exemplo: Redes Neurais.

- Pré-Processamento dos dados é importante: pode ser útil remover tendência. [[Neural network forecasting for seasonal and trend time series, 2005](#)]

ALGUMAS DEFINIÇÕES

Janela de Entrada → Quantos e quais valores passados da série devem ser utilizados;

Horizonte da Previsão → A saída da rede refere-se a quantos passos à frente?

Definição de outras variáveis explicativas → Que outras variáveis podem influenciar na previsão? (exemplos: outras séries históricas (índices financeiros, temperatura), dia da semana, hora da previsão, mês da previsão, etc...)

PREVISÃO DE SÉRIES

☐ Nonlinear Autoregressive with External (Exogenous) Input (NARX)

Predict series $y(t)$ given d past values of $y(t)$ and another series $x(t)$.



☐ Nonlinear Autoregressive (NAR)

Predict series $y(t)$ given d past values of $y(t)$.



☐ Nonlinear Input-Output

Predict series $y(t)$ given d past values of series $x(t)$.


Important Note: NARX solutions are more accurate than this solution. Only use this solution if past values of $y(t)$ will not be available when deployed.




NAR – Nonlinear Autoregressive Model

Previsão de séries temporais com valores da própria série.


NAR




NAR




NAR




NAR




NAR




NAR




NAR




NAR




NAR




NAR



NAR




NAR



NAR

Processo Multi Step (Closed Loop):


- Existe um horizonte da série antes da previsão, e deseja-se prever n passos à frente.
- A própria previsão da rede é utilizada para prever novos valores.
- Erro aumenta conforme aumenta-se o número de previsões à frente.



NAR

Processo One Step Ahead (Open Loop):


- Existe um horizonte da série antes da previsão, e deseja-se prever 1 passo à frente.
- Cada previsão somente é feita quando se tem todos os valores da série histórica imediatamente anteriores ao valor à ser previsto.
- Erro não é propagado para novas previsões.



PREVISÃO DE SÉRIES

● Nonlinear Autoregressive with External (Exogenous) Input (NARX)

Predict series $y(t)$ given d past values of $y(t)$ and another series $x(t)$.



● Nonlinear Autoregressive (NAR)

Predict series $y(t)$ given d past values of $y(t)$.



● Nonlinear Input-Output

Predict series $y(t)$ given d past values of series $x(t)$.


Important Note: NARX solutions are more accurate than this solution. Only use this solution if past values of $y(t)$ will not be available when deployed.



NARX – Nonlinear Autoregressive Model with External

Previsão de séries temporais com valores da própria série e valores de outra série.


NARX



1 simulação



Horizonte: 5 anos
Janela óleo: 3 meses
Janela água: 1 mês



Saída da Rede




	Janela água	Janela óleo			
11/2011	A(3)	O(1)	O(2)	O(3)	O(4)
12/2011	A(4)	O(2)	O(3)	O(4)	O(5)
01/2012	A(5)	O(3)	O(4)	O(5)	O(6)
•					
•					
•					
08/2016	A(59)	O(57)	O(58)	O(59)	O(60)

PREVISÃO DE SÉRIES

● Nonlinear Autoregressive with External (Exogenous) Input (NARX)

Predict series $y(t)$ given d past values of $y(t)$ and another series $x(t)$.



● Nonlinear Autoregressive (NAR)

Predict series $y(t)$ given d past values of $y(t)$.



● Nonlinear Input-Output

Predict series $y(t)$ given d past values of series $x(t)$.

Important Note: NARX solutions are more accurate than this solution. Only use this solution if past values of $y(t)$ will not be available when deployed.




Nonlinear Input-Output

Previsão de séries temporais com valores de outra série.

Atenção: Soluções via NARX são mais precisas que essa solução.

Só utilize esta opção quando não estiverem disponível os dados da própria série a ser prevista.

REDE RECORRENTE



Assunto para disciplina de Redes Neurais!

ESTUDO DE CASO


Previsão de Carga Elétrica

Um sistema preciso de previsão de carga oferece:

**segurança,
confiabilidade e
economia**

na operação de sistemas de potência.

PERFIL DE CARGA HORÁRIA



- - **Terça, Quarta, Quinta e Sexta-Feira**
- ****** - **Sábado**
-** - **Domingo**
- +++** - **Segunda-Feira**

PREVISÃO DE CARGA HORÁRIA

4 redes diferentes de acordo com o dia da semana

Entradas:

- janela de 5 valores passados
- valor da carga 7 dias antes, no mesmo horário
- codificação binária da hora a ser prevista

Treinamento:

- Conjunto de Treinamento: 2 meses anteriores
- Re-treinamento a cada mês

PREVISÃO DE CARGA


Topologia da Rede

Camada de entrada: 11 atributos.

- 5 últimos valores de carga.
- Carga no mesmo dia e hora na semana anterior.
- Codificação binária do horário.


Camada escondida: 20 neurônios.

Camada de saída: 1 neurônio.




PREVISÃO DE CARGA

**Uma semana em Março
168 horas a frente**



— **Valores Reais**
- - - **Valores Previstos**

**1º de agosto
24 horas a frente**



— **Valores Reais**
- - - **Valores Previstos**


ESTUDO DE CASO

Faturamento Varejo



- Mês
- Ano
- Faturamento

ESTUDO DE CASO



**Passageiros de
companhias aéreas.**