

# Sistemas de Apoio a Decisão

## Introdução a Inteligência Artificial



Prof. Manoela Kohler



[prof.manoela@ica.ele.puc-rio.br](mailto:prof.manoela@ica.ele.puc-rio.br)



[www.linkedin.com/in/manoelakohler](https://www.linkedin.com/in/manoelakohler)

# Objetivos de Aprendizagem

Você será capaz de:

- Definir Inteligência Artificial (IA)
  - Machine Learning (ML) e Deep Learning (DL)
- Explicar como DL ajuda a resolver limitações clássicas de ML
- Explicar desenvolvimentos históricos importantes e os ciclos de inverno e hype da IA
- Diferenciar IA moderna de IA clássica
- Entender sobre possibilidades de aplicação da IA.
- Entender o fluxo de um projeto de ML.
- Compreender alguns equívocos comuns na área.

# Computer Vision Master

## Evolução

### Image classification



*"Dog"*



*"Cat"*

As of 2015, computers can be trained to perform better on this task than humans.

### Machine translation

*"I am a student"*



*"Je suis étudiant"*

As of 2016, we have achieved near-human performance using the latest AI techniques.

# Computer Vision Master

Inteligência Artificial é a nova eletricidade, by Andrew Ng

*“About 100 years ago, electricity transformed every major industry. AI has advanced to the point where it has the power to transform ... every major sector in coming years.”*

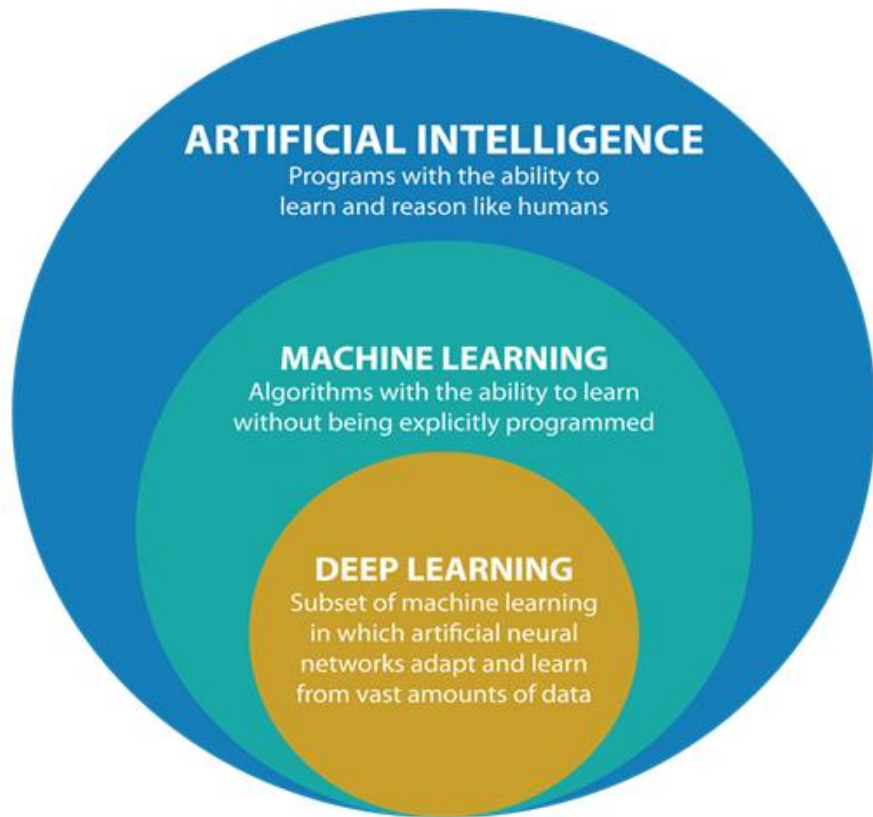
*-Andrew Ng, Stanford University*



# Definições

# Definições

## Definições Básicas



## Inteligência Artificial


“A branch of computer science dealing with the simulation of intelligent behavior in computers.” (Merriam-Webster)

“A program that can sense, reason, act, and adapt.” (Intel)

“Colloquially, the term ‘artificial intelligence’ is applied when a machine mimics ‘cognitive’ functions that humans associate with other human minds, such as ‘learning’ and ‘problem solving’.” (Wikipedia)

# Definições

## Definições Básicas



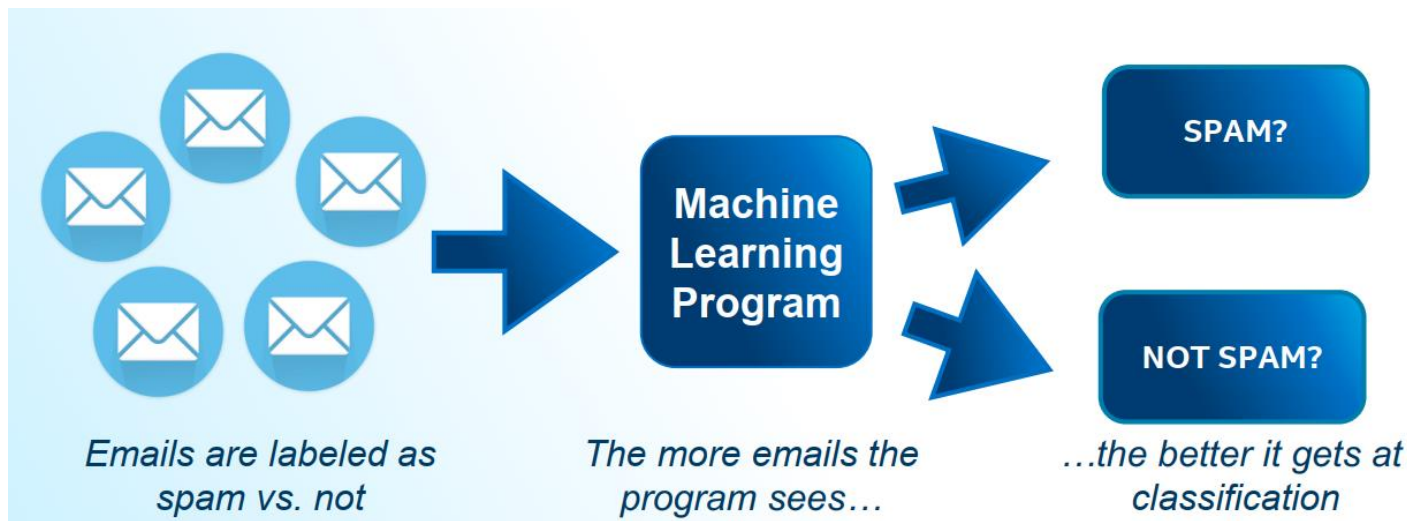
## Aprendizado de Máquina

“The study and construction of programs that are *not explicitly programmed*, but learn patterns as they are exposed to more data over time.” (Intel)

# Machine Learning

## Aprendizado

Estes algoritmos aprendem ao ver repetidamente um conjunto de dados, ao invés de serem explicitamente programados por seres humanos.





# Machine Learning

## Terminologia

Exemplo de base para classificação de espécies de flores.

**Features:**

Attributes of the data.

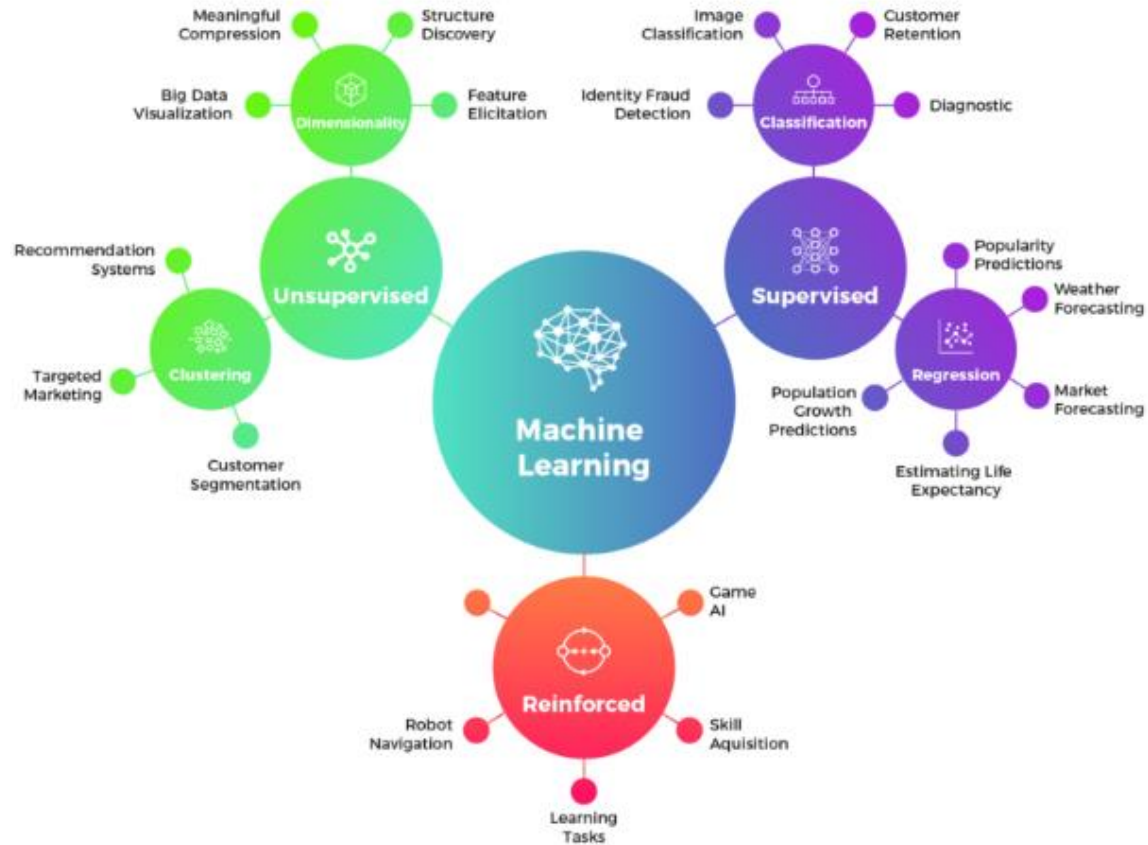
**Target:**

Column to be predicted.

sepal length	sepal width	petal length	petal width	species
6.7	3.0	5.2	2.3	virginica
6.4	2.8	5.6	2.1	virginica
4.6	3.4	1.4	0.3	setosa
6.9	3.1	4.9	1.5	versicolor
4.4	2.9	1.4	0.2	setosa
4.8	3.0	1.4	0.1	setosa
5.9	3.0	5.1	1.8	virginica
5.4	3.9	1.3	0.4	setosa
4.9	3.0	1.4	0.2	setosa
5.4	3.4	1.7	0.2	setosa


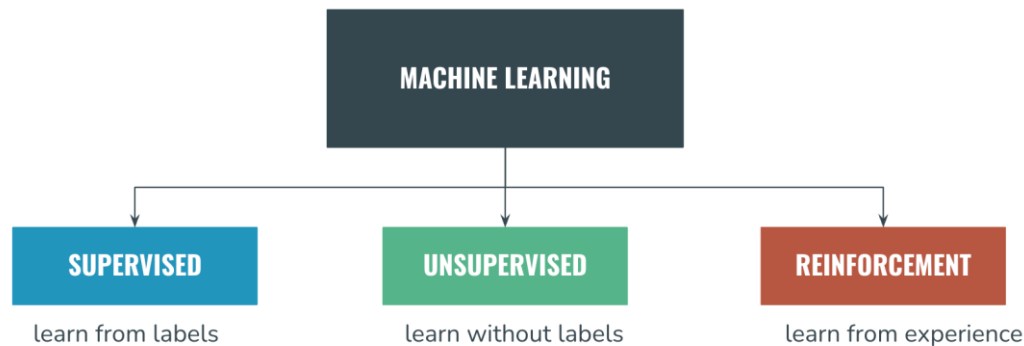
# Machine Learning

## Terminologia



# Machine Learning

## Terminologia



# Machine Learning

## Exemplo

Suponha que você queira identificar transações de cartão de crédito fraudulentas.

Você deveria identificar características para que o algoritmo aprenda que combinações de características sugerem uma atividade incomum, fraudulenta:

- Hora da transação
- Valor da transação
- Localização
- Categoria da compra
- etc...



# Machine Learning

## Limitações

Suponha que você queira determinar se uma imagem é de um gato ou um cão.

Que características você usaria?

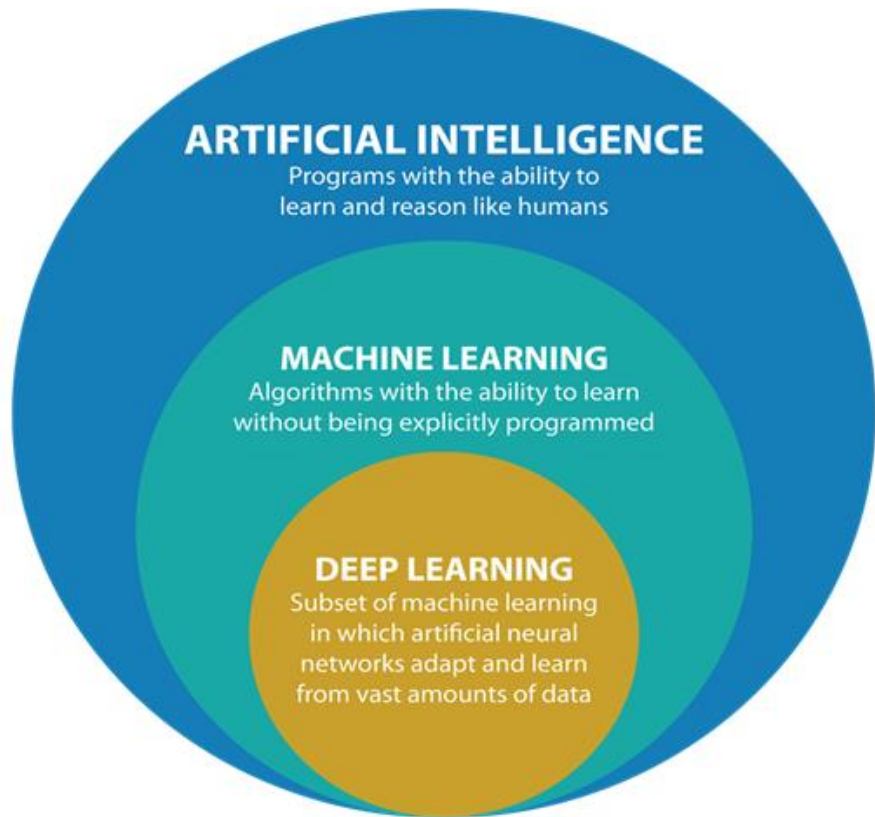
É aí que entra Deep Learning.



*Dog and cat recognition*

# Definições

## Definições Básicas



## Aprendizagem Profunda

“Machine learning that involves using very complicated models called “deep neural networks”.” (Intel)

*Models* determine best representation of original data; in classic machine learning, humans must do this.

# Deep Learning

## Exemplo

### Classic Machine Learning

Step 1: Determine features.

Step 2: Feed them through model.



Feature Detection

Machine Learning Classifier Algorithm


"Arjun"

### Deep Learning

Steps 1 and 2 are combined into 1 step.



Neural Network



"Arjun"



# Deep Learning

## Exemplo



$$\begin{matrix} & 1 & 1 & 1 \\ * & 1 & -8 & 1 \\ & 1 & 1 & 1 \end{matrix} =$$

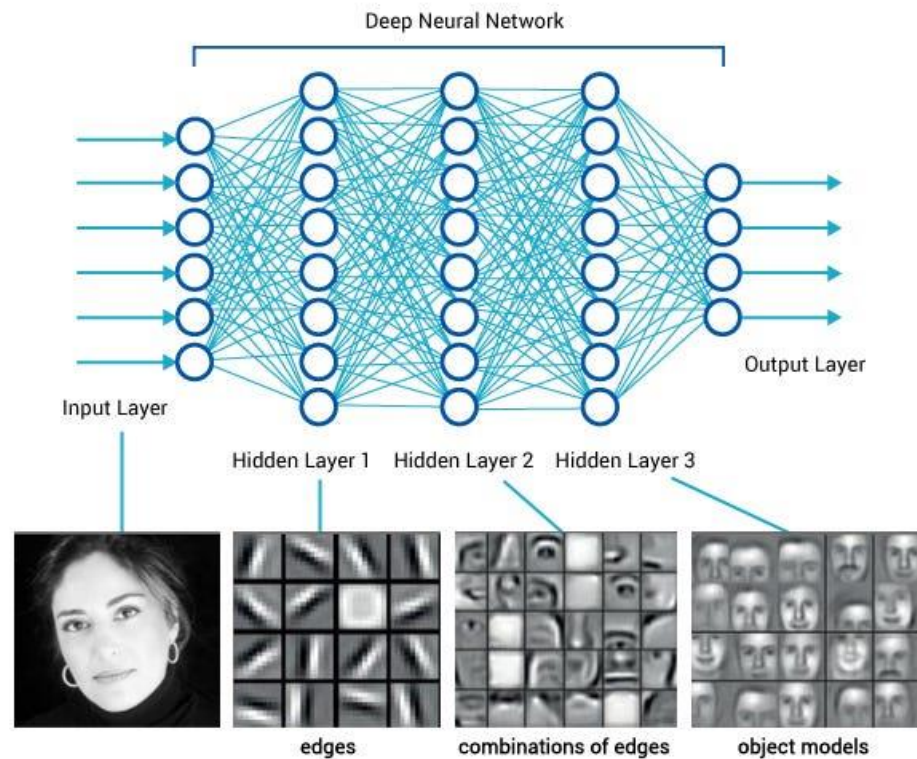




# Deep Learning

## Exemplo

- Diferentes níveis de abstração



# História

# 1950


## Early AI

1950: Alan Turing desenvolveu o teste de Turing para testar a capacidade das máquinas em apresentar um comportamento inteligente.

1956: Inteligência Artificial foi aceita como um campo na Conferência de Dartmouth.

1957: Frank Rosenblatt inventou o algoritmo perceptron. Este foi o precursor das redes neurais modernas.

1959: Arthur Samuel publicou um algoritmo para um programa de damas usando aprendizado de máquina.



# O primeiro inverno da IA

## Early AI

- 1966: comitê da ALPAC avalia técnicas de IA para tradução de máquina e determina que o retorno não compensou o investimento.
- De 1969: Marvin Minsky publicou um livro sobre as limitações do algoritmo Perceptron que retardou a pesquisa em redes neurais.
- 1973: O relatório The Lighthill destaca o fracasso da IA.
- Os dois relatórios levaram a cortes no financiamento do governo para a pesquisa em IA, o que levou-nos ao primeiro “A.I. Winter.”



John R. Pierce, chefe do ALPAC

# Boom da Inteligência Artificial

1980

- Sistemas Especialistas - sistemas com regras programadas concebidas para imitar especialistas humanos.
- Estes sistemas rodavam em mainframes com linguagens de programação especializadas (por exemplo, LISP).
- Foram as primeiras tecnologias de IA amplamente utilizadas, com dois terços da empresas da "Fortune 500" utilizando os sistemas especialistas em seu pico.
- 1986: O algoritmo "Backpropagation" é capaz de treinar perceptrons de múltiplas camadas, o que leva a novos sucessos e interesse na pesquisa de rede neural artificial.



*Early expert  
systems machine*

## Outro “AI Winter”

Final de 1980 – início de 1990

- O progresso dos sistemas especialistas na resolução de problemas de negócios diminuiu.
- Os sistemas especialistas começaram a ser fundidos em aplicativos de negócios gerais (por exemplo, SAP, Oracle), que poderiam funcionar em PCs em vez de mainframes.
- As redes neurais não escalaram a problemas maiores e mais complexos.
- O interesse em IA nos negócios diminuiu.

# Aprendizado de Máquina Clássico

Final de 1990 – início de 2000

- Avanços no algoritmo SVM levaram-no a se tornar o método de escolha.
- Soluções em IA tiveram sucesso em reconhecimento de voz, diagnóstico médico, robótica e muitas outras áreas.
- Algoritmos de IA foram integrados em sistemas maiores e tornou-se útil em todo a indústria.
- O Deep Blue derrotou o campeão mundial de xadrez, Garry Kasparov.
- O motor de busca do Google foi lançado usando inteligência artificial.



*IBM supercomputer*

# A ascensão do Deep Learning

2006

- 2006: Geoffrey Hinton publica um artigo sobre pré-treinamento sem supervisão que permitiu as redes neurais mais profundas serem treinadas.
- O foco de estudo das redes neurais muda para a aprendizagem profunda.
- 2009: O banco de dados ImageNet de imagens rotuladas por humanos é apresentado na conferência CVPR.
- 2010: Algoritmos competem em várias tarefas de reconhecimento visual na primeira competição ImageNet.






# IA Moderna

# Avanços em Deep Learning

2012 até o presente


- Em 2012, Deep Learning bate benchmarks anteriores na competição ImageNet.



# Avanços em Deep Learning

2012 até o presente

- Em 2013, Deep Learning é usado para entender o significado conceitual de palavras.



# Avanços em Deep Learning

2012 até o presente

- Em 2014, avanços semelhantes apareceram na área de tradução.

Google translate vs. “La Bamba”

<https://www.youtube.com/watch?v=06olHmcJjS0>

- Estes acontecimentos levaram a avanços na área de pesquisa na web, pesquisa em documentos, resumo de documentos e tradução de máquina.



*Google Translate*


# Avanços em Deep Learning

2012 até o presente

- Em 2014, algoritmos de visão computacional puderam descrever fotos.
- Em 2015, o framework TensorFlow foi desenvolvido.
- Em 2016, DeepMind AlphaGo, desenvolvido por Aja Huang, derrota Lee Se-dol, o maior campeão de Go.

AlphaGo – The Movie | Full award-winning documentary

<https://www.youtube.com/watch?v=WXuK6gekU1Y>



# Avanços em Deep Learning

2012 até o presente

## Computer vision



Self-driving cars:  
object detection



Healthcare:  
improved diagnosis

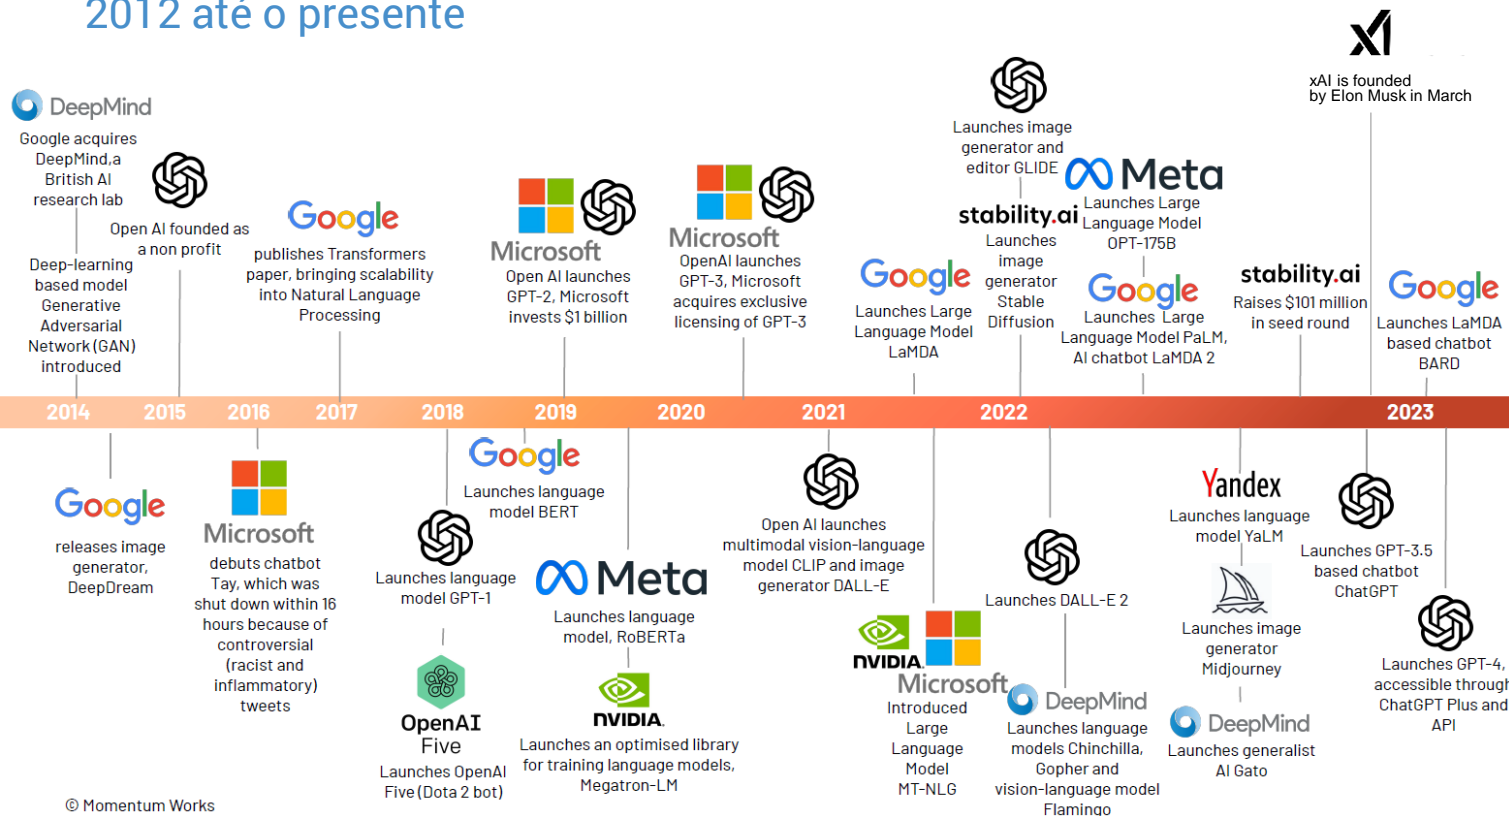
## Natural language



Communication:  
language translation

# Avanços em Deep Learning

## 2012 até o presente



© Momentum Works

## 2024 em diante:

- LLM
- SLM
- VLM
- Modelos multimodais
- Foundation Models
- Ética
- Regulamentação

Grok

# IA

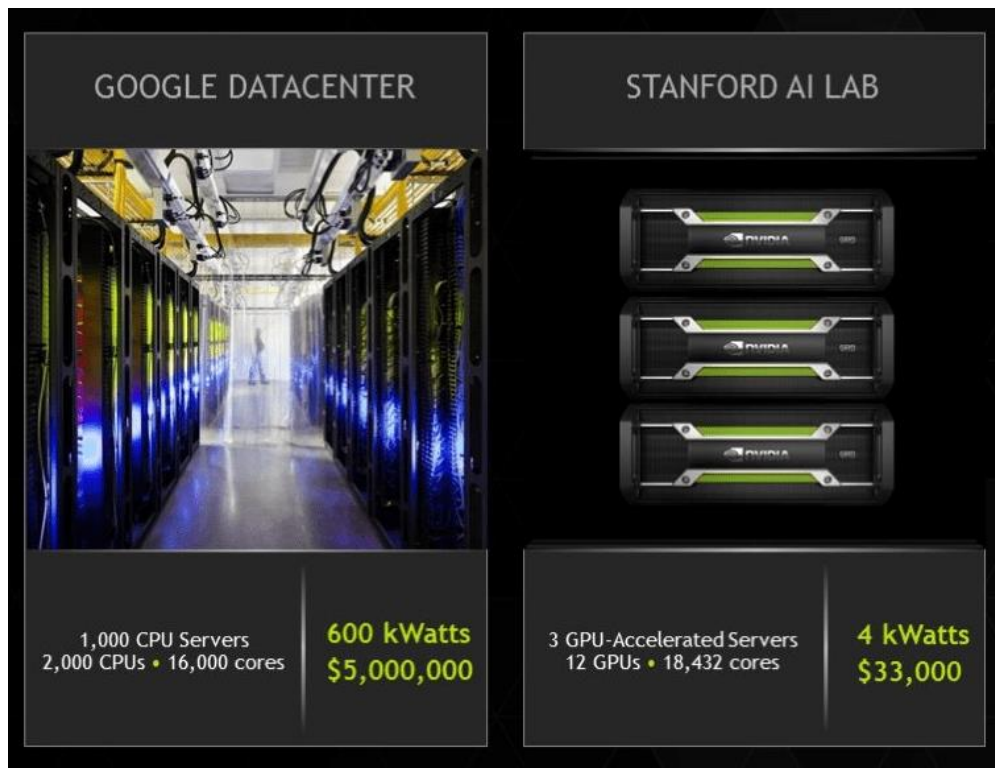
Como essa era é diferente?





# IA

Como essa era é diferente?



# Avanços em Deep Learning

## Mudanças Transformadoras



### Health

- Enhanced Diagnostics
- Drug Discovery
- Patient Care
- Research
- Sensory Aids



### Industrial

- Factory Automation
- Predictive Maintenance
- Precision Agriculture
- Field Automation

# Avanços em Deep Learning

## Mudanças Transformadoras



### Finance

- Algorithmic Trading
- Fraud Detection
- Research
- Personal Finance
- Risk Mitigation



### Energy

- Oil & Gas Exploration
- Smart Grid
- Operational Improvement
- Conservation

# Avanços em Deep Learning

## Mudanças Transformadoras



### Government

Defense  
Data  
Insights  
Safety &  
Security  
Engagement  
Smarter  
Cities



### Transport

Autonomous  
Cars  
Automated  
Trucking  
Aerospace  
Shipping  
Search & Rescue



# Avanços em Deep Learning

## Mudanças Transformadoras



### Other

Advertising

Education

Gaming

Professional &  
IT Services

Telco/Media


Sports

# Aplicações

# Aplicações

## Transporte

### Navigation



Google & Waze find the fastest route, by processing traffic data.

### Ride sharing



Uber & Lyft predict real-time demand using AI techniques, machine learning, deep learning.

# Aplicações

## Mídias Sociais

### Audience



Facebook & Twitter use AI to decide what content to present in their feeds to different audiences.

### Content



Image recognition and sentiment analysis to ensure that content of the appropriate “mood” is being served.



# Aplicações

Dia a dia

## Natural language



We carry around powerful natural language processing algorithms in our phones/computers.

## Object detection

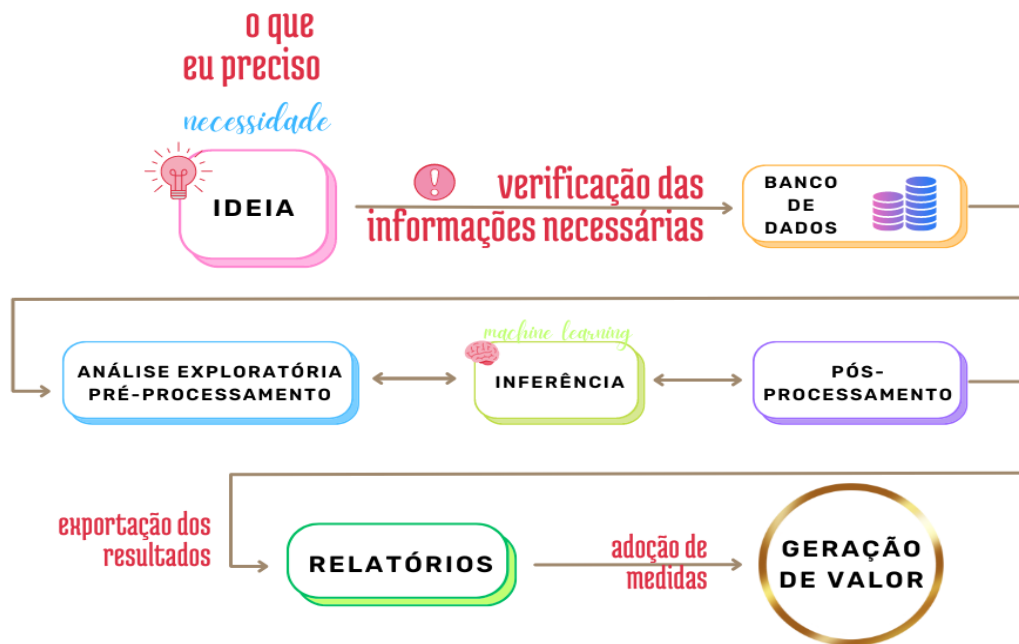


Cameras like Amazon DeepLens\* or Google Clips\* use object detection to determine when to take a photo.

# Fluxo de Trabalho

# Projetos de ML em geral

## Fluxograma



# Equívocos Comuns

# Equívoco #1

## Unicórnio

Cientistas de dados que são especialistas em todas as áreas são chamados de unicórnio.

- Equipes bem-sucedidas contêm pessoas de diversas áreas e formações, com várias habilidades.
- Ex: alguns se distinguem em comunicação, enquanto outros se sobressaem em estatística.
- Equipes bem-sucedidas têm especialistas em três áreas principais: negócios, ciência e engenharia.

## Equívoco #2

Foco em pesquisa e algoritmos

Equipes de ciência de dados não podem focar apenas em pesquisa e algoritmos.

- Boas equipes conseguem:
  - Identificar problemas;
  - Comunicar suas descobertas;
  - Trabalhar com a engenharia para achar o melhor método de produção.



## Equívoco #3

### Sistemas complexos e avançados

A solução mais complicada nem sempre é a melhor.


- Equipes tendem a ser mais bem sucedidas quando começam do básico e, em seguida, passam para técnicas mais complexas de modelagem.
- Modelos complexos podem ser mais precisos, contudo eles são menos interpretáveis, isto é, mais propícios a falharem de forma imprevisível e mais difíceis de sustentar.
- Começar do básico também garante que o projeto da equipe se alinhe com as necessidades do negócio.

## Equívoco #4

### Diferenças na indústria

Técnicas de modelagem e análise de dados são amplamente disseminadas entre indústrias.

- É necessário conhecimento do domínio para entender quais são os dados e problemas mais relevantes.
- As técnicas usadas para limpar e armazenar dados, assim como extrair insights e modelagem úteis, são similares.






## Equívoco #5

### Projetos começam bem definidos

Projetos de ciência de dados normalmente são exploratórios e experimentais.

- Geralmente não é claro o quão difícil a solução do problema será até se explorar os dados.
- Gerentes de produto devem trabalhar com a equipe e demais pessoas envolvidas no projeto para gerenciar as expectativas.

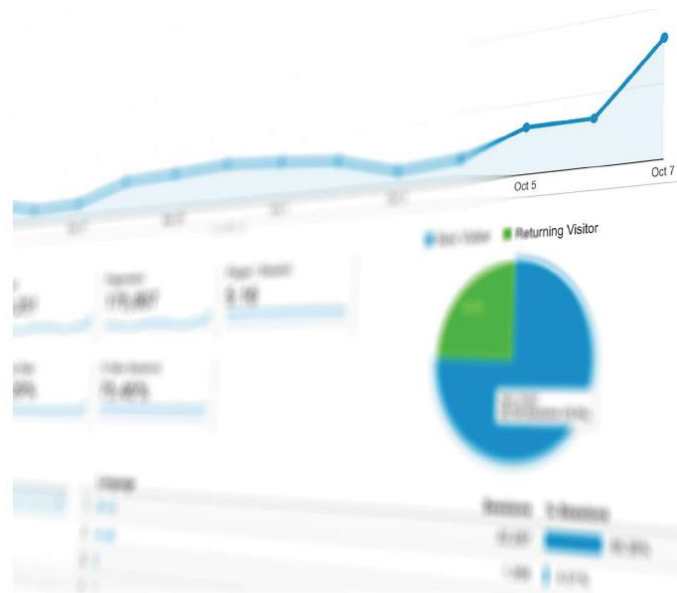


## Equívoco #6

Os melhores modelos de previsão são os mais avançados

Há mais desafios envolvidos na escolha de um modelo do que a sua capacidade de previsão.

- Alguns modelos podem ser lentos ou complicados demais para incluir na produção.
- Alguns modelos podem não ser interpretáveis, tornando investidores mais relutantes.



# Obrigada!

Prof. Manoela Kohler



[prof.Manoela@ica.ele.puc-rio.br](mailto:prof.Manoela@ica.ele.puc-rio.br)



[www.linkedin.com/in/manoelakohler](https://www.linkedin.com/in/manoelakohler)